天津大学
Tianjin University

Combating Concept Drift with Explanatory Continuous exploration and diverse collision: a two-way advancement of academic speculation

持续深挖与多元碰撞：学术思辨的双向进阶

汇 报 人：董敏弘　　指导老师：许光全

汇报日期：2026-9-19

目录

01 研讨主线

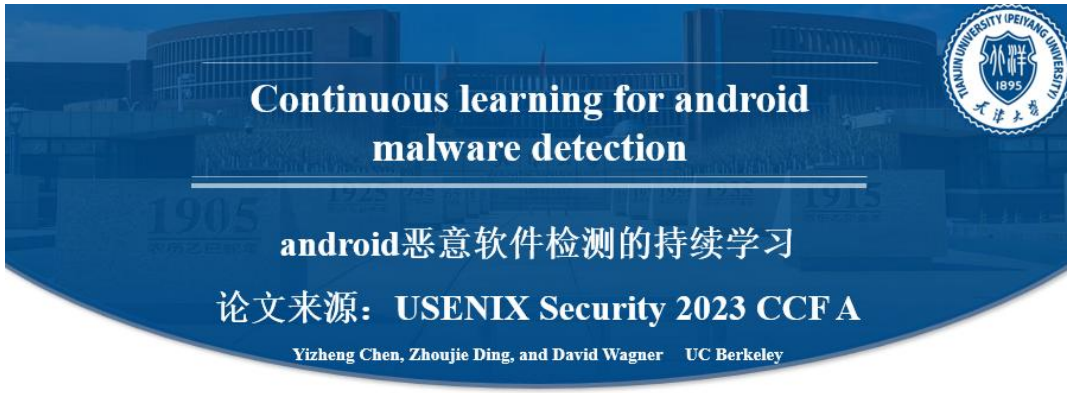
02 纵向深挖

03 横向拓展

04 思辨总结

天津大学 Tianjin University

1. 研讨主线



汇报人：董敏弘
指导老师：许光全，王聪



汇报人：董敏弘
指导老师：许光全，王聪
2025年12月4日

四次研讨始终围绕含噪声环境下的 Android 恶意软件检测展开，从不同角度分析噪声与不确定性对模型训练、检测和持续适应带来的影响。随着研讨推进，关注点逐步从模型如何应对环境变化，深入到标签可信性、漂移原因以及不同噪声机制，形成一条持续深化的研究主线。

Tianjin University

Combating Concept Drift with Explanatory Detection and Adaptation for Android Malware Classification

结合解释性检测与自适应机制的 Android 恶意软件概念漂移对抗方法

Yiling He, Junchi Lei, Zhan Qin, Kui Ren, Chun Chen；Zhejiang University

汇 报 人：董敏弘　　指导老师：许光全　　汇报日期：2026-3-23

Tianjin University

Seeking Certainty from Uncertainty: A Training Framework for Android Malware Detection Resilient to Label Noise

从不确定性中寻求确定性：一种抗标签噪声的Android恶意软件检测训练框架

Cuiying Gao, Hanwen Zhang, Heng Li, Wei Zhou, Haolan Zhang, Yueming Wu, Wei Yuan, Yang Liu；Huazhong University of Science and Technology

汇 报 人：董敏弘　　指导老师：许光全　　汇报日期：2026-6-15

1. 研讨主线

第一次

Continuous Learning for Android Malware Detection

概念漂移 · 持续学习 · 主动学习 · 类别不平衡 · 模型动态适应

第二次

Deep Learning from Imperfectly Labeled Malware Data

研讨汇报不应只是对不同论文的独立介绍，而应尽可能围绕自身研究领域持续选题和深入。通过连续关注相关问题，可以逐步积累对研究背景、关键问题、方法思路与技术边界的认识，使每一次汇报都成为前一次思考的延伸，并为后续研究提供新的问题和启发。

可解释漂移检测 · 漂移解释 · 解释指导的模型适应

第四次

Seeking Certainty from Uncertainty: Training Resilient to Label Noise

随机噪声 · 实例依赖噪声 · 可靠监督信息

论文不同，但研究领域高度集中：含噪声与不确定环境下的 Android 恶意软件检测

1.研讨主线

研讨选题不追求彼此独立的**新颖话题**，而应尽可能围绕自身研究领域展开，使每次汇报都与自身研究保持持续关联。

不同论文可以采用**不同切入点**，但应**围绕一个**相对稳定的**核心**问题展开，使多个主题之间能够形成联系。

通过**相关主题的组合**，逐步覆盖研究方向中的不同关键侧面，使零散论文阅读逐渐形成较完整的领域认识。

主线选题要点

（1）研究方向聚焦

（2）核心问题关联

（3）研究内容覆盖

研讨主线的核心，不是让每次汇报内容相同，而是让不同选题始终围绕自身研究方向形成关联。

2. 纵向深挖

模型如何适应持续变化?

恶意软件不断演化，概念漂移使固定模型逐渐失效，由此引出持续学习与模型动态适应问题。

模型学习的标签是否可信?

持续获取新数据并不能保证监督信息可靠，自动化标注带来的标签冲突与错误，使研究进一步转向不完美标签和数据可信问题。

从“持续适应漂移”→“理解并解释漂移”，从“处理不完美标签”→“在复杂噪声下寻找可靠监督”

发现漂移之后，如何更有效地完成模型更新?

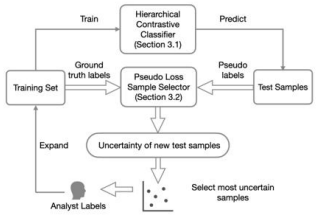
仅识别漂移样本仍然需要较高的人工标注与分析成本，因此进一步引入行为概念和可解释信息，让漂移检测、原因解释与模型适应形成联动

面对不同类型的标签噪声，如何获得更可靠的监督?

标签噪声具有不同类型和复杂分布，单纯依赖噪声识别、删除或纠正容易受到识别误差影响。研究进一步转向从模型预测与数据结构中寻找可靠监督，提高模型在不同噪声环境下的鲁棒性。

“持续适应漂移” → “理解并解释漂移”

本方案的持续学习框架以 “主动学习循环 + 层次对比学习 + 伪损失样本选择” 为核心，分为 5 个关键步骤，实现模型的持续迭代与性能维持：



01 **初始化训练** 基于初始数据集（如 2012 年 APIGraph 数据）训练层次对比分类器，包含编码器（生成样本嵌入）和分类器（预测恶意 / 良性标签）两个子网络。

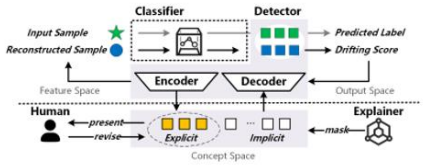
02 **样本不确定性计算** 对新流入的测试样本，通过 “伪损失” 计算不确定性得分，综合编码器的嵌入相似度与分类器的预测置信度。

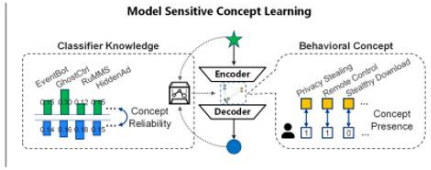
03 **样本筛选** 选择不确定性最高的样本（如每月 200 个）交由分析师标注，获取恶意 / 良性标签及恶意家族标签。

04 **模型增量更新** 采用热启动策略（基于历史模型权重继续训练），将新标注样本加入训练集，用层次对比损失与分类损失联合更新模型。

05 **性能评估与循环** 在次月测试集上评估模型性能，重复步骤 2-4，实现持续学习。

DREAM: distinguished by model-sensitive drift detection and explanatory adaption for Android malware classification





- **Concept-based Drift Detection**
- **（基于概念的漂移检测）**
- **Explanatory Drift Adaptation**
- **（解释性漂移适应）**

发现漂移，就等于理解漂移吗？

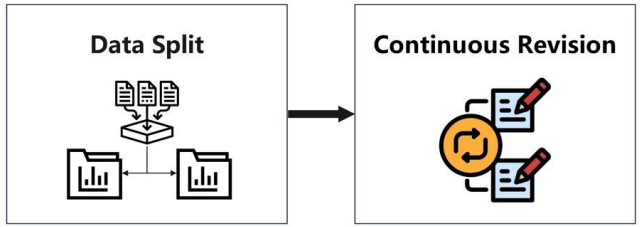
持续适应漂移

- 检测不再是一次性任务，而是持续性任务——模型需要在部署之后继续吸收新知识，跟随数据分布一起演化。

理解并解释漂移

- 哪些偏移真正影响模型决策？漂移不只是需要"应对"的异常，更是可以被分析和利用的信息

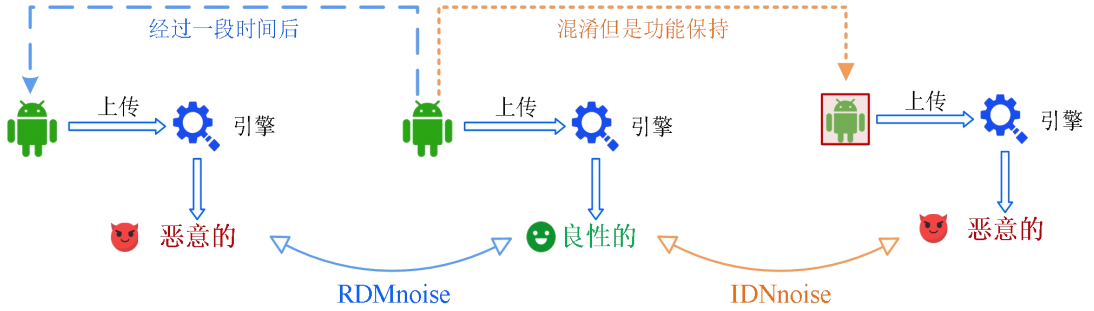
2. 纵向深挖



论文提出 SLB 框架，主要由数据分割和持续更新模块组成，其核心思想是让模型在训练过程中自动判断哪些标签可靠，并持续修正那些可能错误的标签。

01 将数据自动划分为“可信”与“不可信”两部分，为后续的标签修正提供结构化输入。

02 持续更新模块机制的本质动机是让模型在训练中自行完善标签质量，实现“自校正式学习”，最终输出更高质量的干净集和更鲁棒的分类器。



“处理不完美标签” → “在复杂噪声下寻找可靠监督”

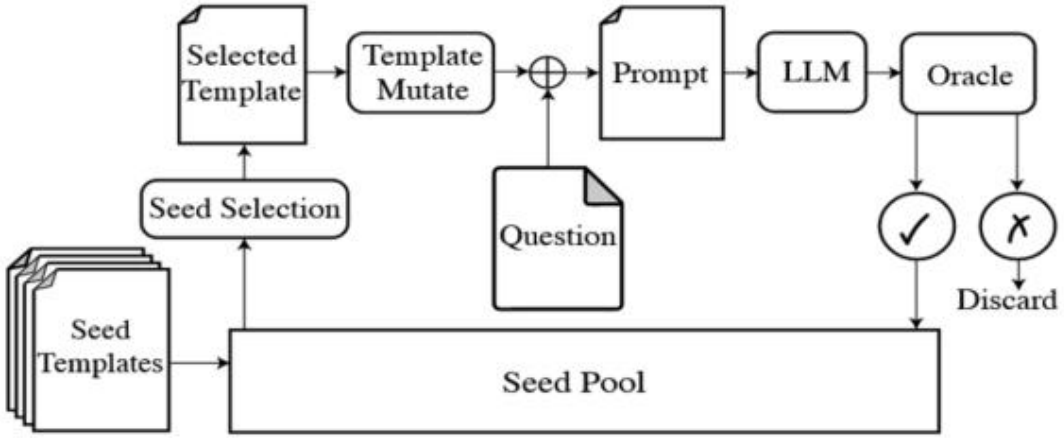
自动化引擎能够提供大规模标签，但不同引擎的结论可能互相冲突，标签之间可能存在冲突与错误。更多数据 ≠ 更可靠的信息。因此提出的SLB方法则是在基于一个较强的前提“干净的样本在训练中预测会快速稳定，而噪声样本会保持波动”下提出的方法

论文通过捕捉到模型对于噪声的敏感性，通过早停机制从模型层面优化噪声，再通过聚类方法从数据结构分布角度来优化噪声问题。两方面的结合有效的减少了噪声。同时方法不仅仅只删除样本，还有纠正机制，提升了样本的利用率。

但是在恶意软件检测中，部分恶意软件家族的样本数较少，全部丢弃则会造成严重的数据不平衡问题

2.LLM-Fuzzer

LLM-Fuzzer 工作流程的示意图



- **Seed initialization（种子初始化）**
- **Seed selection（种子选择）**
- **Mutation（变异）**
- **Inference（推理）**
- **Oracle evaluation（Oracle评估）**

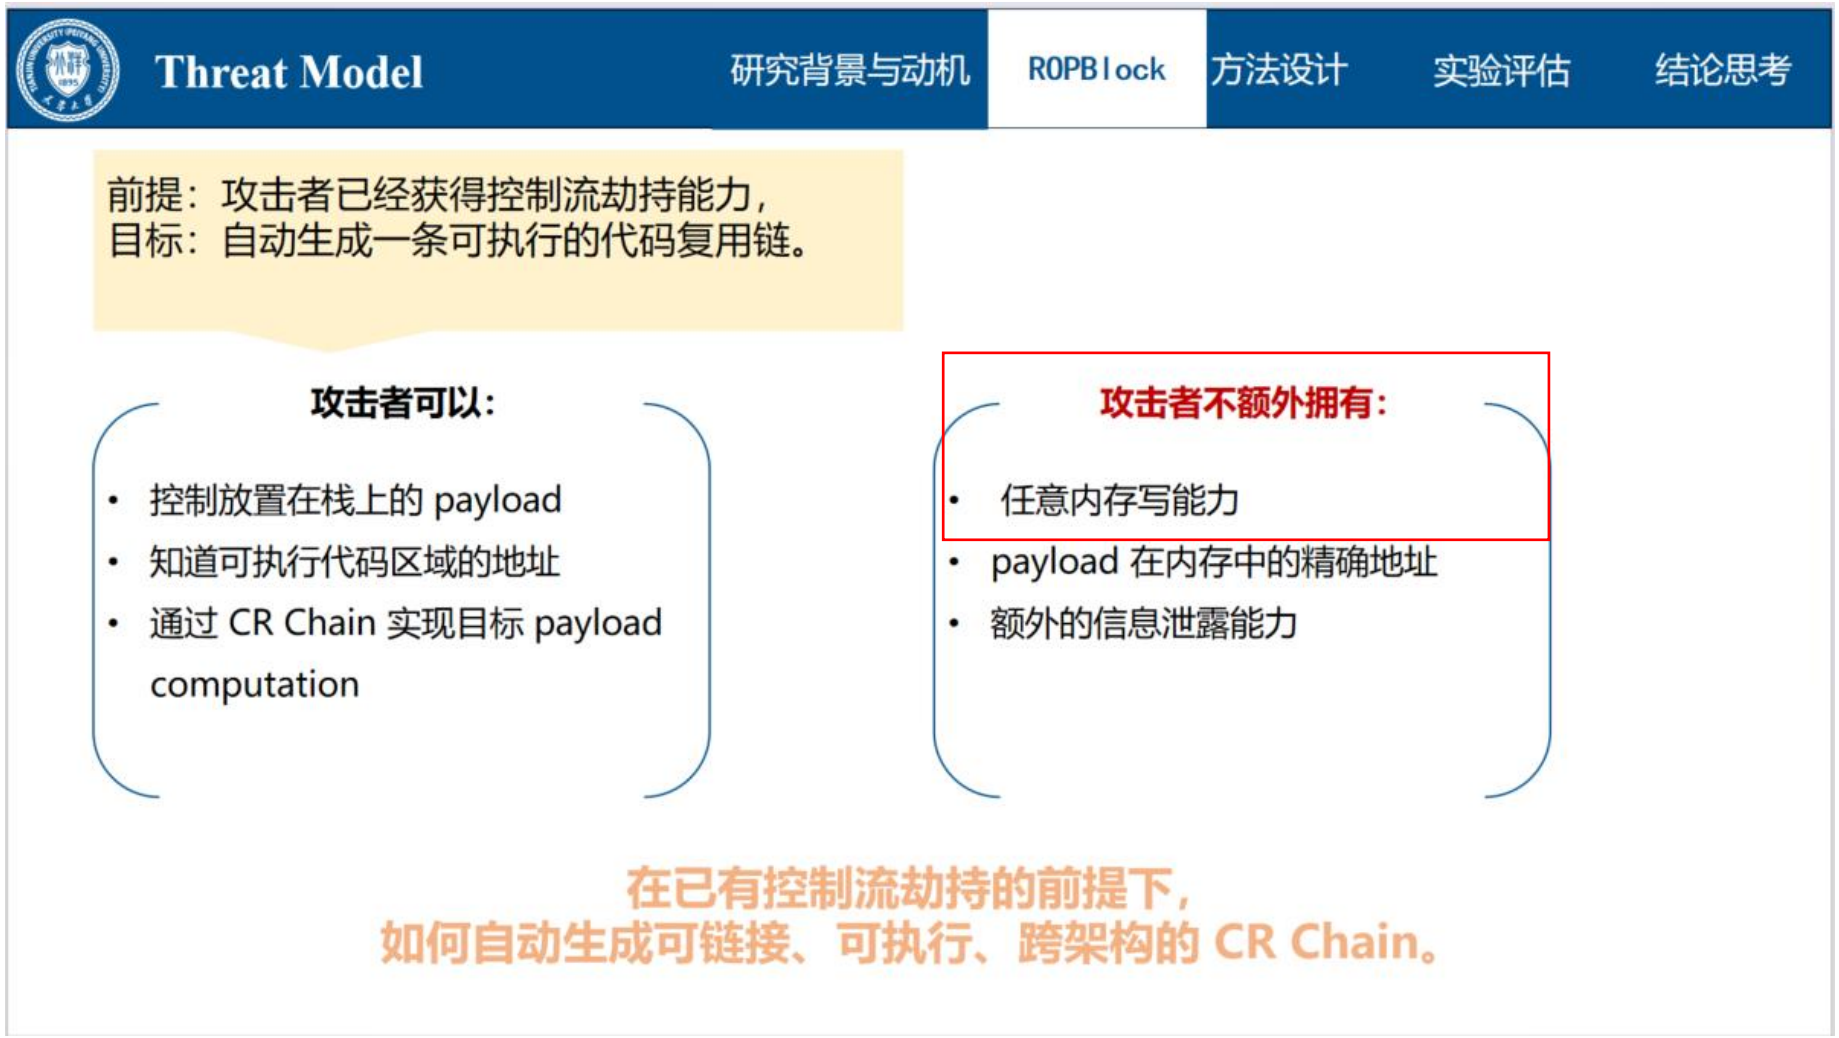
Seed initialization

作者从 Liu 等人 [34] 的工作中汇集了一批手工编写的模板。剔除不适用于本实验的模板后，共保留了 77 个模板，构成了他们的种子模板池。随后他们从两个公开数据集 [7, 34] 中抽取不道德问题，直到得到一组 100 个问题——这些问题均无法被种子模板池中任何人工编写的模板在 Llama-2-7B-Chat 与 Gpt-3.5-turbo-0125 上成功越狱。

[34] Yi Liu, Gelei Deng, Zhengzi Xu, Yuekang Li, et al. **Jailbreaking chatgpt via prompt engineering: An empirical study.**

[7] Yuntao Bai, Andy Jones, Kamal Ndousse, et al. **Training a helpful and harmless assistant with reinforcement learning from human feedback.**

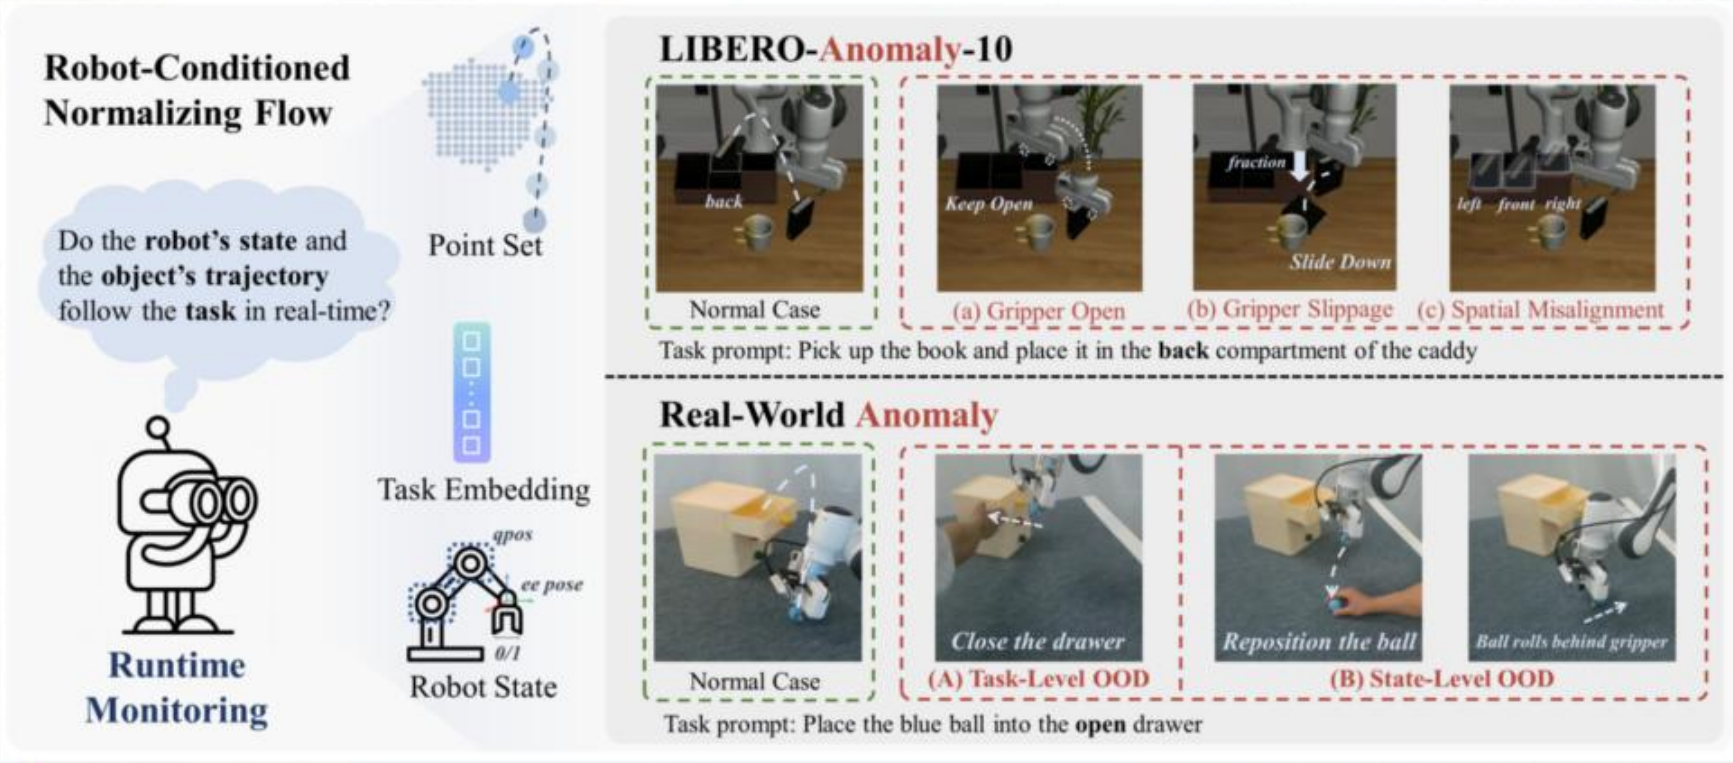
ropbot: Reimaging Code Reuse Attack Synthesis



研究背景

天津大学 Tianjin University

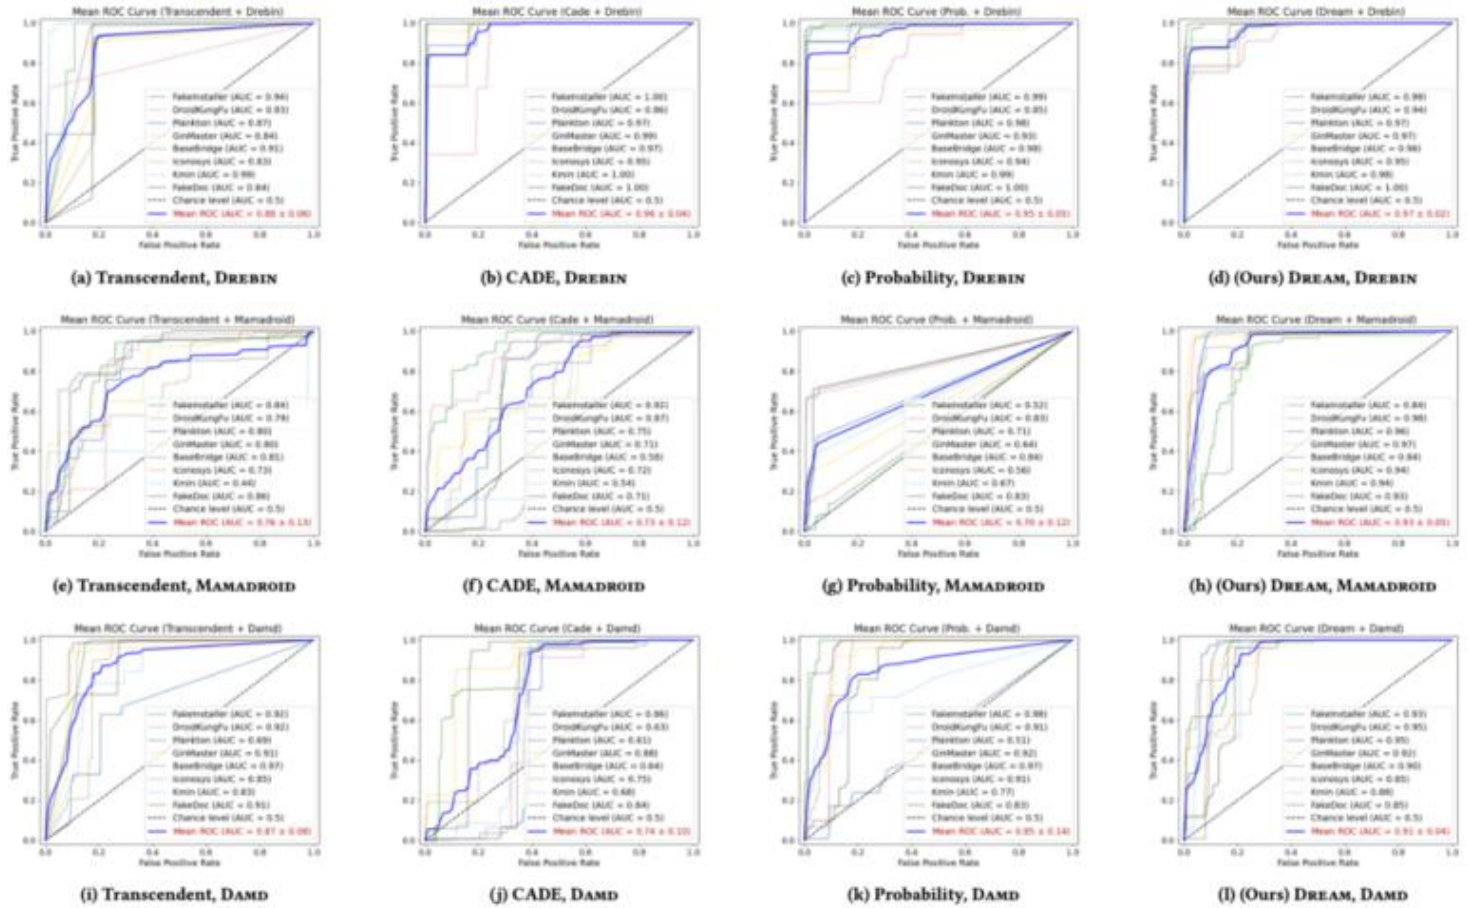
为了解决上述问题，作者提出了一种实时异常检测模型---机器人条件归一化流方法（Robot-Conditioned Normalizing Flow, RC-NF），用于监测机器人状态和任务相关物体轨迹的联合分布是否与正常任务执行一致。



实事求是

3.横向拓展

实验1：漂移检测的性能



(a) Transcendent, Drebin　(b) CADE, Drebin　(c) Probability, Drebin　(d) (Ours) Dream, Drebin

(e) Transcendent, Mamadroid　(f) CADE, Mamadroid　(g) Probability, Mamadroid　(h) (Ours) Dream, Mamadroid

(i) Transcendent, Damd　(j) CADE, Damd　(k) Probability, Damd　(l) (Ours) Dream, Damd

Figure 5: Evaluation of inter-class drift detection on Drebin dataset with three feature spaces. The first three columns are Transcendent, CADE, Probability, respectively, and our method is on the last column.

基线方法	基线方法
Transcendent	用统计置信度来判断预测是否可靠
CADE	对比学习进行漂移检测
概率基线	通过不确定性进行判断

评价指标

AUC： ROC 曲线下面积，越接近1越好

4.思辨总结

纵向深挖

围绕同一方向，把问题想深

- 持续追问
- 发现局限
- 审视假设
- 理解本质

×

横向拓展

借助不同方向，把边界拓宽

- 听取不同方向
- 比较研究路径
- 提出问题
- 迁移思维方式

深挖问题 × 拓展边界

求源、熵减、思辨

学术思辨不仅是找到一个答案

围绕自身研究方向持续研讨，可以让分散的论文逐渐形成研究主线；

持续追问能够推动认识从现象走向问题、从方法走向本质；

不同方向的交流与提问，则帮助拓展研究边界和科研判断。

把自己的问题想深，也借助别人的问题重新理解自己的问题。



感谢观看

敬请各位老师同学批评指正