# 方班研讨厅论文选题及案例分析

吴联仁
广州大学黄埔方班教研室

2026年09月19日



# 目　录


01 选题来源

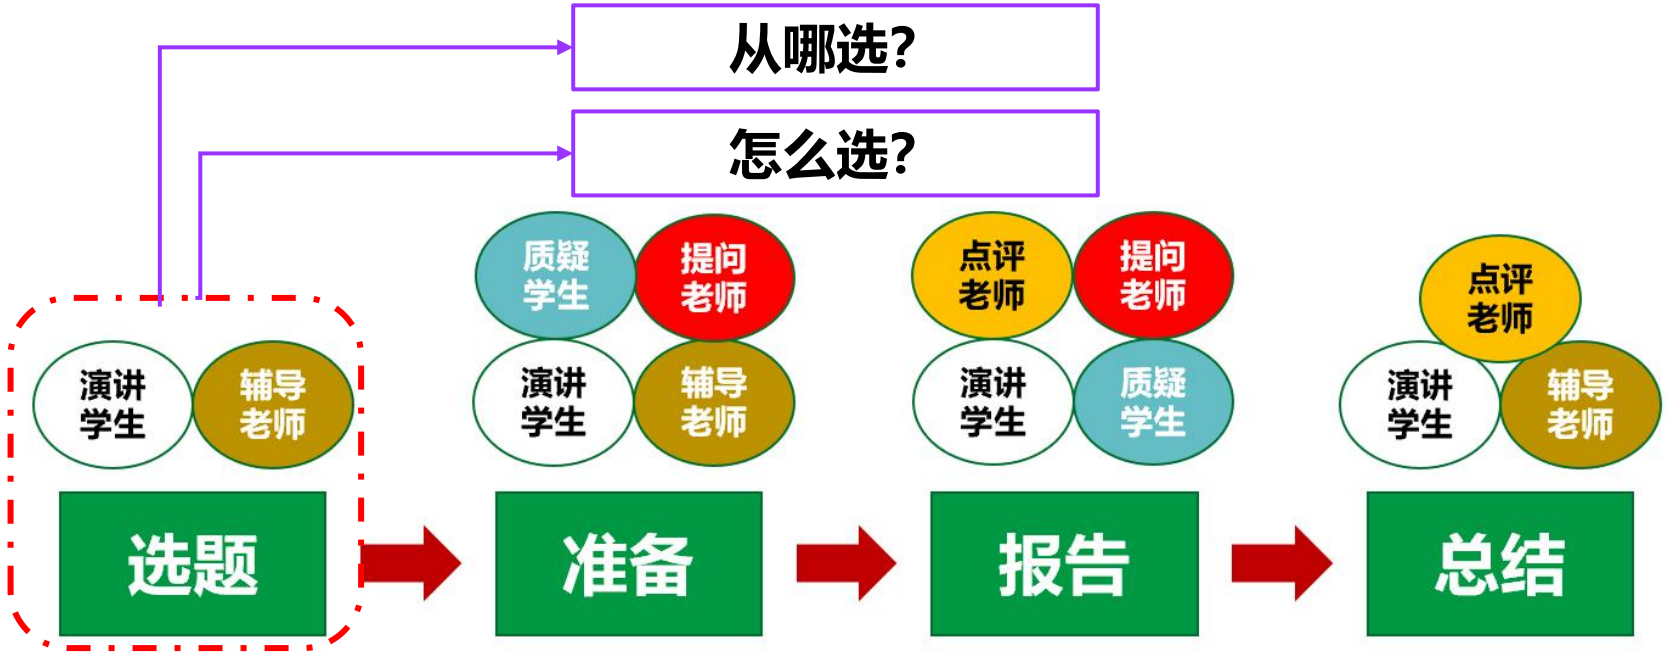
02 负面案例

03 正面案例

04 选题建议

# 论文选题

## 方班研讨厅的4个重要环节



# 从兴趣走向学术价值

◆ **如何选择一篇值得分享的论文?**

## ☑优秀的选题具备

- 与课程内容/研究方向/研究前沿契合
- 与研究方法相匹配（如强化学习、对比学习等）
- 发表在顶会/期刊（NeurIPS, ICML, CVPR...）
- 阅读门槛合适，有启发性观点

## 🛠 工具辅助

- Google Scholar / Arxiv
- Connected Papers / Zotero
- DeepSeek 等大模型辅助选题
- 关注领域公众号，快速了解领域前沿






# 论文选题之9类

1. 网络空间理论
2. 密码学及应用
3. 网络与系统安全
4. 信息与内容安全
5. 应用与新兴技术安全
6. 数据安全与隐私保护
7. 人工智能安全及应用
8. 区块链及安全
9. 物联网及安全

## 细化主题 精准匹配

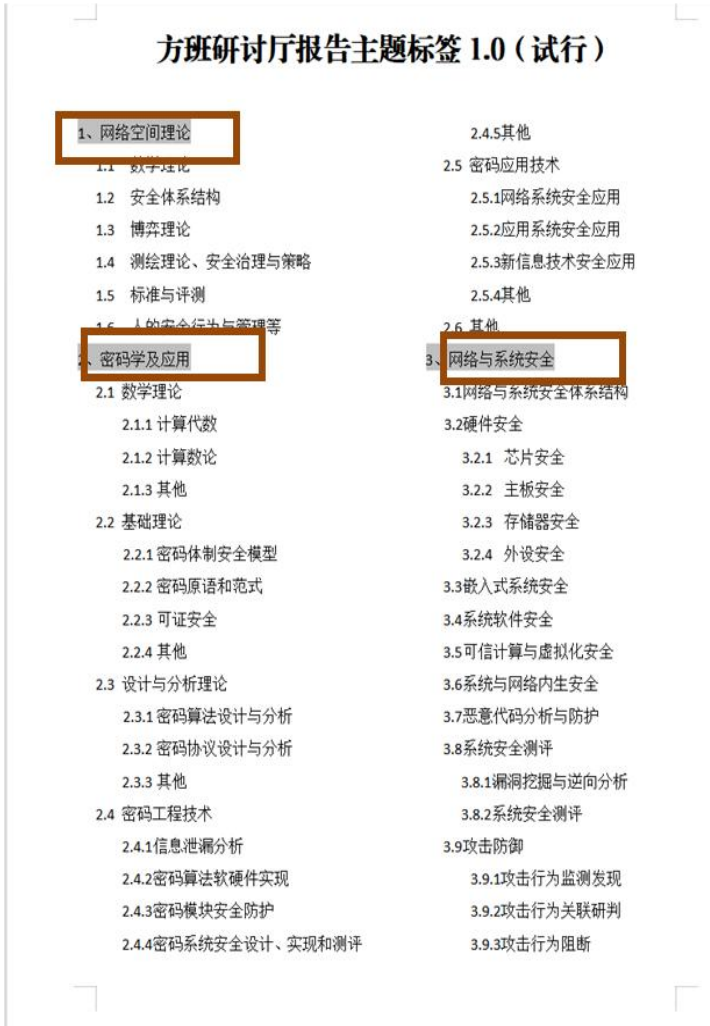
构建多层级主题标签：

从哪选

**9类** 一级主题

**27类** 二级主题

**若干** 三级主题



方班研讨厅报告主题标签 1.0（试行）

1、网络空间理论
1.1 数学理论
1.2 安全体系结构
1.3 博弈理论
1.4 测绘理论、安全治理与策略
1.5 标准与评测
1.6 人的安全行为与管理等
2、密码学及应用
2.1 数学理论
2.1.1 计算代数
2.1.2 计算数论
2.1.3 其他
2.2 基础理论
2.2.1 密码体制安全模型
2.2.2 密码原语和范式
2.2.3 可证安全
2.2.4 其他
2.3 设计与分析理论
2.3.1 密码算法设计与分析
2.3.2 密码协议设计与分析
2.3.3 其他
2.4 密码工程技术
2.4.1信息泄漏分析
2.4.2密码算法软硬件实现
2.4.3密码模块安全防护
2.4.4密码系统安全设计、实现和测评
2.4.5其他
2.5 密码应用技术
2.5.1网络系统安全应用
2.5.2应用系统安全应用
2.5.3新信息技术安全应用
2.5.4其他
2.6 其他
3、网络与系统安全
3.1网络与系统安全体系结构
3.2硬件安全
3.2.1 芯片安全
3.2.2 主板安全
3.2.3 存储器安全
3.2.4 外设安全
3.3嵌入式系统安全
3.4系统软件安全
3.5可信计算与虚拟化安全
3.6系统与网络内生安全
3.7恶意代码分析与防护
3.8系统安全测评
3.8.1漏洞挖掘与逆向分析
3.8.2系统安全测评
3.9攻击防御
3.9.1攻击行为监测发现
3.9.2攻击行为关联研判
3.9.3攻击行为阻断
3.10网络安全应急响应
3.11网络通信安全
3.12网络基础设施安全
3.13网络与信息对抗
3.14其他
4、信息内容安全
4.1多模态信息获取与识别
4.2多模态信息筛选与过滤
4.3网络信息安全管理
4.4内容理解与舆情分析
4.5信息关联与情报分析
4.6信息挖掘
4.7社交网络
4.8其他
5、应用与新兴信息技术安全
5.1数据库安全
5.2大数据平台安全（含数据追踪溯源）
5.3软件定义安全（含网络虚拟化安全）
5.4云安全
5.5云原生
5.6身份认证与管理
5.7电子政务系统安全
5.8电子商务系统安全
5.9电子支付安全
5.10关键信息基础设施安全
5.11其他
6、数据安全与隐私保护
6.1数据隐私保护
6.2安全多方计算
6.3同态加密
6.4数字版权保护
6.5信息隐藏
6.6其他
7、人工智能安全及应用
7.1人工智能安全
7.2人工智能对抗
7.3人工智能算法
7.4神经网算法
7.5知识图谱
7.6强化学习
7.7自然语言处理
7.8其他
8、区块链及安全
8.1共识机制及安全
8.2智能合约及安全
8.3公链及安全
8.4私链及安全
8.5联盟链及安全
8.6其他
9、物联网及安全
9.1工业控制系统及安全
9.2智慧城市及安全
9.3传感网及安全
9.4其他

# 论文选题之来源

| 领域 | 会议简称 | 会议全称 | 出版社 |
|---|---|---|---|
| 网络与信息安全 | CCS | ACM Conference on Computer and Communications Security | ACM |
| | EUROCRYPT | International Conference on the Theory and Applications of CryptographicTechniques | Springer |
| | S&P | IEEE Symposium on Security and Privacy | IEEE |
| | CRYPTO | International Cryptology Conference | Springer |
| | USENIX Security | USENIX Security Symposium | USENIX Association |
| | NDSS | Network and Distributed System Security Symposium | ISOC |
| 数据库/数据挖掘/内容检索 | SIGMOD | ACM SIGMOD Conference | ACM |
| | SIGKDD | ACM SIGKDD Conference on Knowledge Discovery and Data Mining | ACM |
| | ICDE | IEEE International Conference on Data Engineering | IEEE |
| | SIGIR | International ACM SIGIR Conference on Research and Development in Information Retrieval | ACM |
| | VLDB | International Conference on Very Large DataBases | Morgan Kaufmann/ACM |
| 人工智能 | AAAI | AAAI Conference on Artificial Intelligence | AAAI |
| | NeurIPS | Conference on NeuralInformation Processing Systems | MIT Press |
| | ACL | Annual Meeting of the Association for Computational Linguistics | ACL |
| | CVPR | IEEE/CVF Computer Vision and Pattern Recognition Conference | IEEE |
| | ICCV | International Conference on Computer Vision | IEEE |
| | ICML | International Conference on Machine Learning | ACM |
| | IJCAI | International Joint Conference on Artificial Intelligence | Morgan Kaufmann |

**中国计算机学会推荐国际学术会议和期刊目录**

**第七版（2026）**

**网络与信息安全A类会议**

**NDSS， CCS， USENIX Security ， IEEE S&P ，EUROCRYPT，CRYPTO**

**A类期刊**

**TDSC**, IEEE Transactions on Dependable and Secure Computing

**TIFS**, IEEE Transactions on Information Forensics and Security

**Journal of Cryptology**

# 选题原则“五选六不选”

**五选**

1、**锁定所从事方向持续跟进：**导师主导，按照课题组的要求选择；
2、**研习本领域中有代表性的文章：**方向确定，从核心方法入手；
3、**关注兴趣方向以求探索：**方向不确定，从已有基础的角度出发；
4、**关注热点以寻找机会：**方向不确定，跟随热点来快速进入角色；
5、**选择系统性分析的文章**：从经典文章入手来学习写文章的方法。

**六不选**

- **不选本人成果：**我们是教学，不是考试，要尝试掌握他人的观点；
- **不选早期文章：**要与时俱进，从最新研究成果中了解研究方法；
- **不选综述文章、技术标准、宏观方案、实验统计：**我们不是学知识，我们是学方法，所以那些固化了的知识、不具有思辨的内容不选。

# 为什么不能选？——先避坑

- **不选本人成果：**我们是教学，不是考试，要尝试掌握他人的观点；
- **不选早期文章：**要与时俱进，从最新研究成果中了解研究方法；
- **不选综述文章、技术标准、宏观方案、实验统计：**我们不是学知识，我们是学方法，所以那些固化了的知识、不具有思辨的内容不选。

**六不选**

# 为什么不能选?

1. 面向研究生一年级的课程
2. 训练学生三种方法（求源、熵减、思辨）
3. 以顶级刊物学术文献为教材
4. 设在秋春两学期共128课时

**方班研讨厅是一门“学生讲、师生问、专家评”的互动式思辨课程**

存在问题 →

- 早期文章、综述文章分享意义不大
- 技术标准、宏观方案、实验统计类论文难以形成讨论问题
- 本人成果达不到训练效果

教学目标 →

求源方法　　熵减方法　　思辨方法



# 目　录


01 选题来源

02 负面案例

03 正面案例

04 选题建议

# 案例一

方班示范班第118期 (4月13日) 教学2班

LANGUAGE MODELS ARE ADVANCED ANONYMIZERS [1]

大语言模型是高级匿名器 (ICLR 2025)

Staab, R., Vero, M., Balunovic, M., & Vechev, M. (2025). Language models are advanced anonymizers. In *The Thirteenth International Conference on Learning Representations*.

ICLR，全称为「International Conference on Learning Representations」(国际学习表征会议), 是深度学习领域的顶级国际会议之一。CCF A 会议

# 案例一

## 汇报目录

一 研究背景与课题意义

二 论文的主要研究内容

三 研究工作总结及展望

PPT包括3页目录总计16页、对论文的概要以PPT形式呈现。

求源

## ■ 研究背景与课题意义

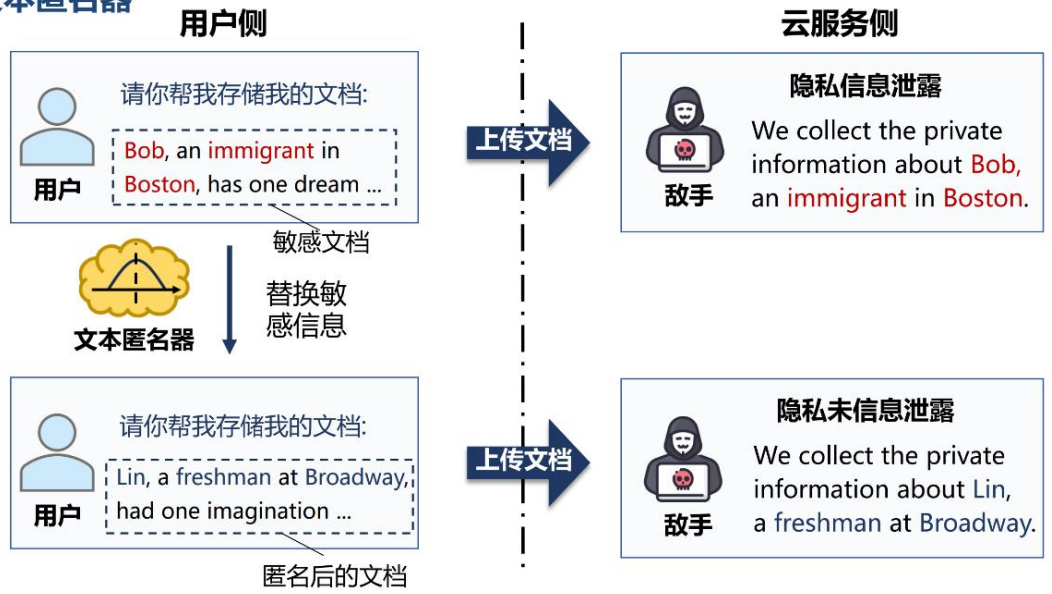
### □ 文本匿名器的发展




大语言模型的发展为文本匿名技术带来了新的机遇

## ■ 研究背景与课题意义

### □ 文本匿名器



# 案例一

## 汇报目录


一 研究背景与课题意义

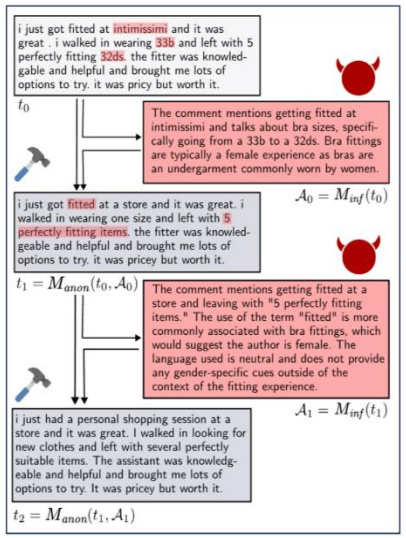
二 论文的主要研究内容

三 研究工作总结及展望

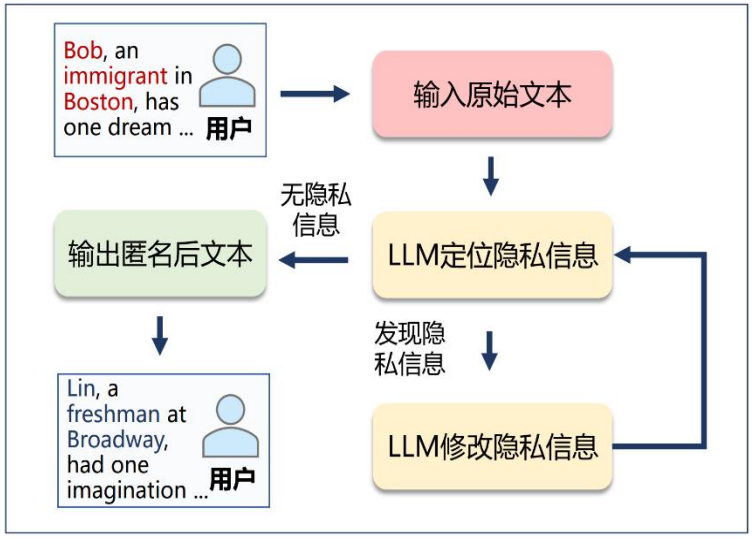

**PPT的制作和讲解缺少自己的理解和逻辑。**

## ■ 大语言模型是高级匿名器

### □ 本文方案




本文框架概览




本文方案技术流程图

## ■ 大语言模型是高级匿名器

### □ 概述

本文[1]利用大语言模型提供了当前先进的文本匿名技术：

- ✓ 提出了一种利用大语言模型的新型文本匿名框架
- ✓ 克服了当前文本匿名技术的测试的局限性
- ✓ 全面评估了此前流行的文本匿名技术方案

本文代表利用大语言模型进行文本匿名的初步尝试


Published as a conference paper at ICLR 2025

LANGUAGE MODELS ARE ADVANCED ANONYMIZERS

Robin Staab, Mark Vero, Mislav Balunović, Martin Vechev
Department of Computer Science, ETH Zurich
{robin.staab, mark.vero}@inf.ethz.ch

ABSTRACT

Recent privacy research on large language models (LLMs) has shown that they achieve near-human-level performance at inferring personal data from online texts. With ever-increasing model capabilities, existing text anonymization methods are currently lacking behind regulatory requirements and adversarial threats. In this work, we take two steps to bridge this gap: First, we present a new setting for evaluating anonymization in the face of adversarial LLM inferences, allowing for a natural measurement of anonymization performance while remedying some of the shortcomings of previous metrics. Then, within this setting, we develop a novel LLM-based adversarial anonymization framework leveraging the strong inferential capabilities of LLMs to inform our anonymization procedure. We conduct a comprehensive experimental evaluation of adversarial anonymization across 13 LLMs on real-world and synthetic online texts, comparing it against multiple baselines and industry-grade anonymizers. Our evaluation shows that adversarial anonymization outperforms current commercial anonymizers both in terms of the resulting utility and privacy. We support our findings with a human study (n=50) highlighting a strong and consistent human preference for LLM-anonymized texts.

1 INTRODUCTION

The rapidly increasing capabilities and widespread adoption of large language models (LLMs) (OpenAI, 2023; Touvron et al., 2023b) have sparked various discussions about their potential impacts on society. An area of particular interest has been the privacy implications of LLMs, where initial investigations focused primarily on the memorization of model training data (Carlini et al., 2021; 2023). Recently, it has been shown that modern LLMs can be misused for high-accuracy predictions of personal attributes from seemingly non-revealing online posts (Staab et al., 2023). Moreover, where previously one would have to hire humans to infer private attributes, these models are fast and cheap enough to automate such inferences at scale. Concurrently, as users are unaware of such issues, they continue to share texts with information easily inferable by LLMs. Rather concerningly, prior work has also shown that current industry-standard text anonymizers are largely insufficient at protecting users from such attacks, as they are unable to pick up on revealing yet complex and context-dependent cues. Consider the following shortened example from Staab et al. (2023):

*This left shark thing is hilarious, I've seen it, walked just by them to see it live after my final exams.*

While the comment contains no direct references to any locations, the context allows both an informed reader and an LLM to infer that the author lived in Glendale, where the 2015 Super Bowl halftime show featured a performance colloquially called "left shark incident." It would thus be desirable if the user could be warned before posting the comment that it might reveal their location and, ideally, be offered a less revealing alternative. Yet, anonymizing this text with existing tools proves futile, as no location was directly mentioned, fooling traditional entity-recognition-based anonymizers. This is particularly alarming as there have already been reports of LLM inferences being commercially applied online to categorize users based on their posts (Brewster, 2023).

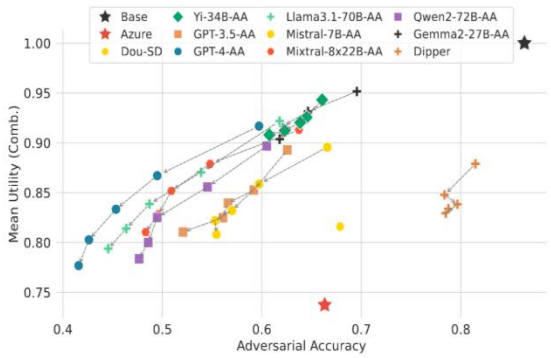
**The Need for Privacy** At the same time, there has been a large regulatory push for stronger individual privacy protection. Notably, regulations such as the EU's GDPR (EU, 2016) and California's CCPA (Cal, 2018) have established extensive legislative requirements to protect individuals' private data, such as location, age, and sex. Complementing regulatory efforts, online users, e.g., on pseudonymized sites like Reddit, are also increasingly aware of the need to protect their privacy and demand tighter governance over their personal data.

1

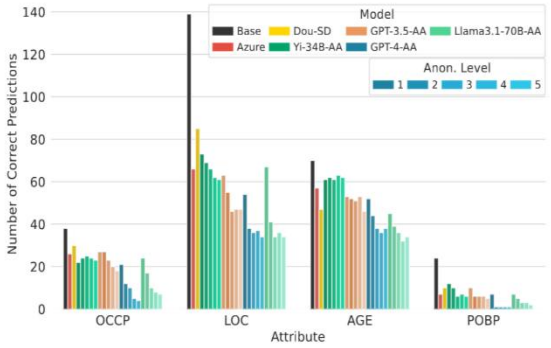
# 案例一

## 实验结果

- 大语言模型是高级匿名器
  - 主实验结果




(a) Utility-privacy tradeoff

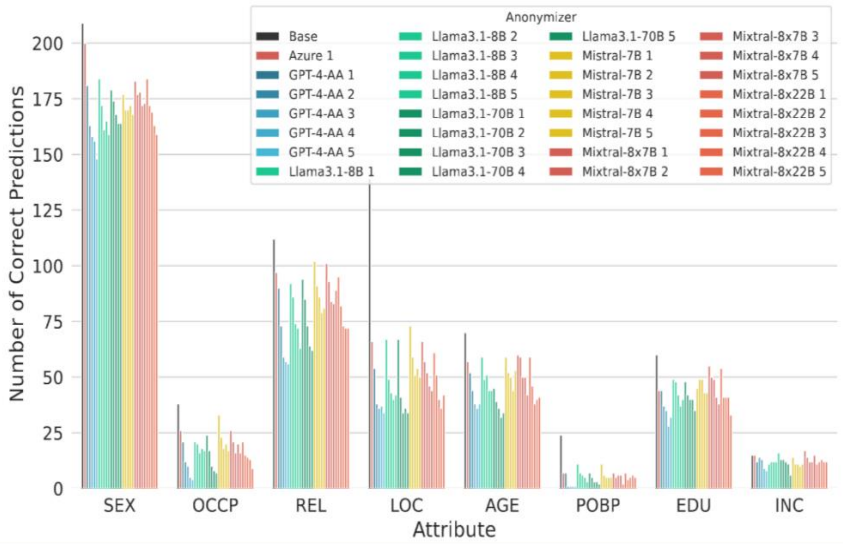



(b) Per-attribute adversarial accuracy

大语言模型能有效保护用户隐私信息并平衡数据的可用性

## 实验结果

- 大语言模型是高级匿名器
  - 成员推理攻击实验结果




大语言模型对于不同类别数据的保护效果存在差异化

# 案例一

## 汇报目录


一 研究背景与课题意义

二 论文的主要研究内容

三 研究工作总结及展望


**论文偏实验统计，无法形成有效讨论和启发。**

**研究结论和展望是对论文原文的翻译，缺少思辨。**

## ■ 研究工作总结

### □ 大语言模型是高级匿名器

本文利用大语言的先进能力开发了前沿的文本隐私匿名工具。本文的实验结果表明，大语言模型较已有的匿名化工具具有更强的隐私保护能力同时兼顾匿名后文本的可用性维持。

本文呼吁，在大语言模型时代，我们需要开发更强大的隐私保护方案以进一步应对前沿的大语言模型所带来的隐私攻击威胁。



Published as a conference paper at ICLR 2025

LANGUAGE MODELS ARE ADVANCED ANONYMIZERS

Robin Staab, Mark Vero, Mislav Balunović, Martin Vechev
Department of Computer Science, ETH Zurich
{robin.staab, mark.vero}@inf.ethz.ch

ABSTRACT

Recent privacy research on large language models (LLMs) has shown that they achieve near-human-level performance at inferring personal data from online texts. With ever-increasing model capabilities, existing text anonymization methods are currently lacking behind regulatory requirements and adversarial threats. In this work, we take two steps to bridge this gap: First, we present a new setting for evaluating anonymization in the face of adversarial LLM inferences, allowing for a natural measurement of anonymization performance while remedying some of the shortcomings of previous metrics. Then, within this setting, we develop a novel LLM-based adversarial anonymization framework leveraging the strong inferential capabilities of LLMs to inform our anonymization procedure. We conduct a comprehensive experimental evaluation of adversarial anonymization across 13 LLMs on real-world and synthetic online texts, comparing it against multiple baselines and industry-grade anonymizers. Our evaluation shows that adversarial anonymization outperforms current commercial anonymizers both in terms of the resulting utility and privacy. We support our findings with a human study (n=50) highlighting a strong and consistent human preference for LLM-anonymized texts.

1 INTRODUCTION

The rapidly increasing capabilities and widespread adoption of large language models (LLMs) (OpenAI, 2023; Touvron et al., 2023b) have sparked various discussions about their potential impacts on society. An area of particular interest has been the privacy implications of LLMs, where initial investigations focused primarily on the memorization of model training data (Carlini et al., 2021; 2023). Recently, it has been shown that modern LLMs can be misused for high-accuracy predictions of personal attributes from seemingly non-revealing online posts (Staab et al., 2023). Moreover, where previously one would have to hire humans to infer private attributes, these models are fast and cheap enough to automate such inferences at scale. Concurrently, as users are unaware of such issues, they continue to share texts with information easily inferable by LLMs. Rather concerningly, prior work has also shown that current industry-standard text anonymizers are largely insufficient at protecting users from such attacks, as they are unable to pick up on revealing yet complex and context-dependent cues. Consider the following shortened example from Staab et al. (2023):

*This left shark thing is hilarious, I've seen it, walked past by there to see it live after my final exams.*

While the comment contains no direct references to any locations, the context allows both an informed reader and an LLM to infer that the author lived in Glendale, where the 2015 Super Bowl halftime show featured a performance colloquially called "left shark incident." It would thus be desirable if the user could be warned before posting the comment that it might reveal their location and, ideally, be offered a less revealing alternative. Yet, anonymizing this text with existing tools proves futile, as no location was directly mentioned, fooling traditional entity-recognition-based anonymizers. This is particularly alarming as there have already been reports of LLM inferences being commercially applied online to categorize users based on their posts (Brewster, 2023).

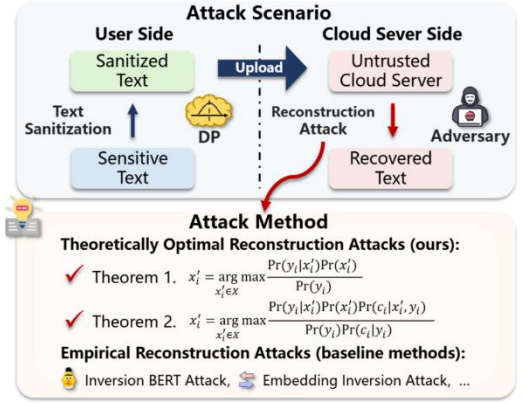
**The Need for Privacy** At the same time, there has been a large regulatory push for stronger individual privacy protection. Notably, regulations such as the EU's GDPR (EU, 2016) and California's CCPA (Cal, 2018) have established extensive legislative requirements to protect individuals' private data, such as location, age, and sex. Complementing regulatory efforts, online users, e.g., on pseudonymized sites like Reddit, are also increasingly aware of the need to protect their privacy and demand tighter governance over their personal data.

1

## ■ 研究工作展望

### □ 测量文本匿名工具的隐私保护上界 *NAACL 2025, Oral, Top 2% of Submissions*

利用贝叶斯定理，建立文本匿名工具的最优重构攻击[2]。







2: **Meng Tong, Kejiang Chen** * et al. "On the Vulnerability of Text Sanitization." In Proceedings of the Main Conference of the 2025 NAACL

# 问题在哪?

**六不选** 不选本人成果；不选早期文章；不选综述文章
不选技术标准；不选宏观方案；不选实验统计

- **现场情况：**

**汇报时间，10:20-10:28，报告时间8分钟，报告后1名质疑学生提问，进行了简单交流。**

- **原因**

**论文选题偏实验统计，可讨论性低，难以形成讨论问题。**



# 案例二

# 软硬件协同加速RTL模拟
# Accelerating RTL Simulation with Hardware-Software Co-Design

From:MICRO '23: 56th Annual IEEE/ACM International Symposium on Microarchitecture

**方班示范班第114期 2025年3月16日**

**IEEE/ACM International Symposium on Microarchitecture（MICRO）是计算机体系结构领域的顶级国际会议，与ISCA、HPCA、ASPLOS并列计算机体系结构四大顶会。CCF A类 会议**

# 案例二

**PPT没有目录，总计20页。**

## 研究背景与动机

- 模拟器(Simulator)运行速度慢。
- 仿真器(Emulator)编译时间长。

⇩

- ASH(Accelerator of Simulated Hardware):

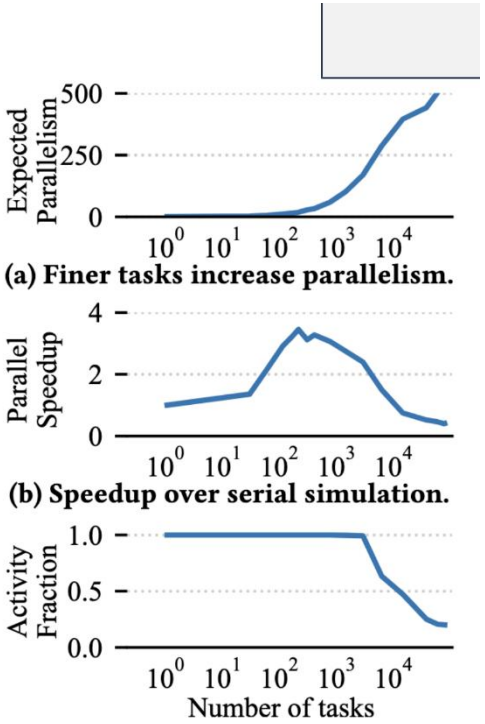
  保留软件模拟快速编译的优点的同时获得显著的加速效果。

## 优化机会

- 基于数据流执行的硬件模拟加速

⇩

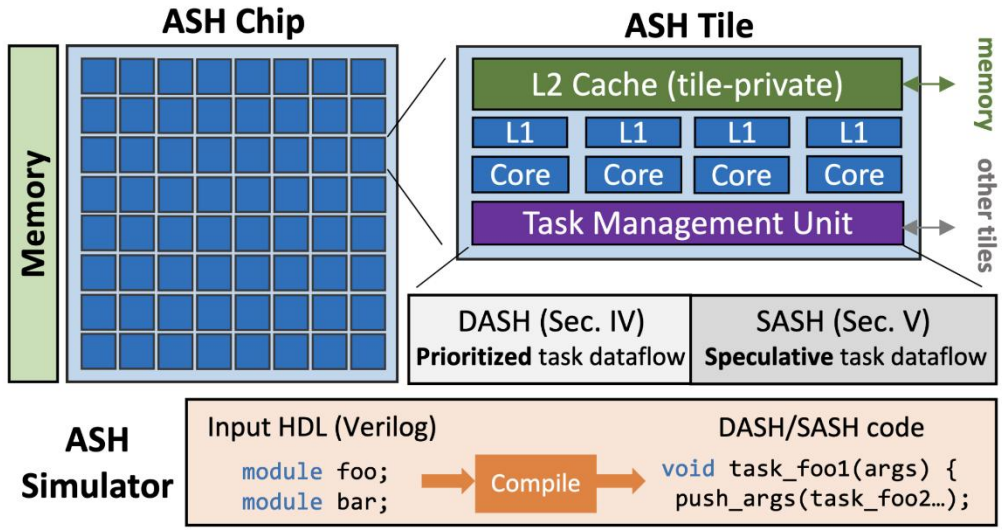
- 利用数据并行性



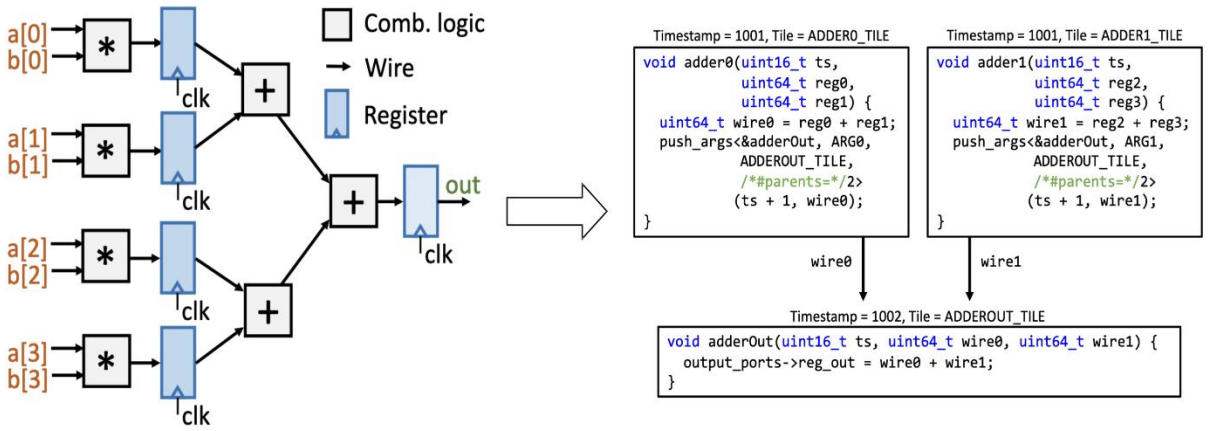
# 案例二

**论文偏宏观方案，缺少核心算法、基本原理和背景知识。**

## 系统概述：软硬件系统




## DASH具体实现：执行模型



# 案例二

## 实验评估

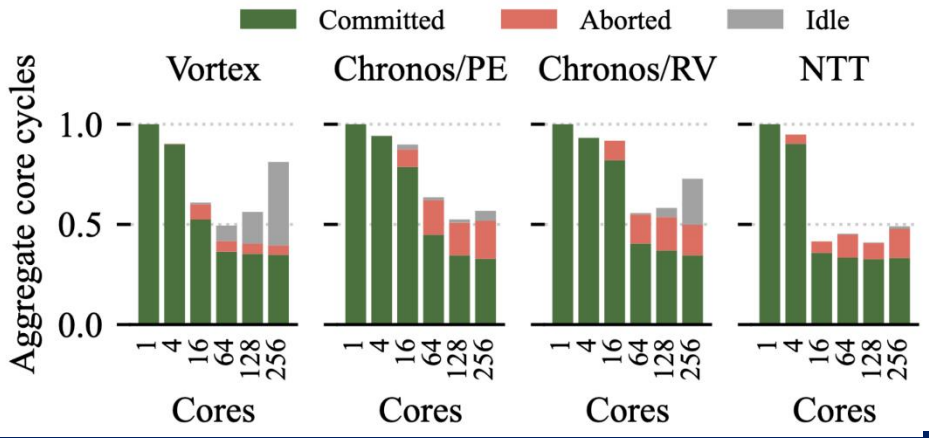
➢ 基准系统

1. 32核的AMD Zen 2 CPU，主频3.5GHz

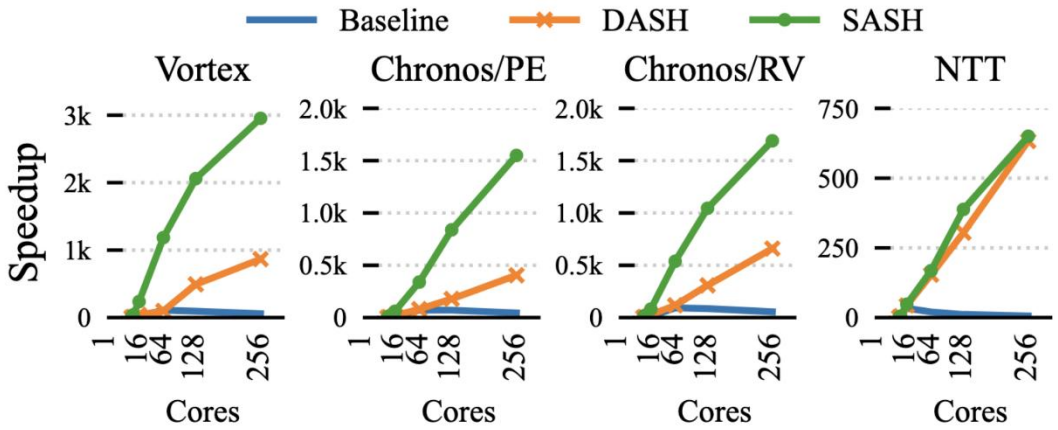
2. 模拟多核系统，其配置如下

| | |
|---|---|
| Cores | 256个按序标量核心分布在64个tile中，2.5 GHz，x86-64基础指令集，带记分牌，使用阻塞式流水线，8字节宽的2级指令预取，两级分支预测器：512×10位BHSR+ 1024×2位PHT，3级解码，1级发射，2-5级后端，16项加载/存储队列。 |
| L1 caches | 每核心16 KB L1数据缓存和16 KB L1指令缓存，8路组相联，2周期延迟。 |
| L2 caches | 每tile 1 MB，16路组相联，包含式缓存，9周期延迟。 |
| NoC(片上网络) | 16×16网格拓扑，X-Y路由，直行时每跳1周期，转弯时2周期，2.5GHz频率。 |

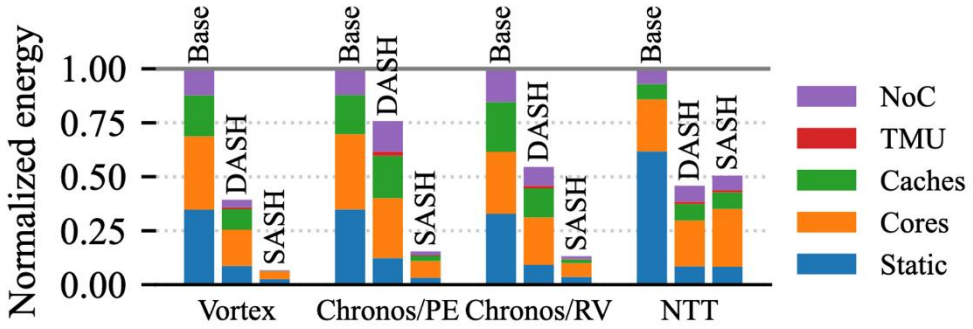
## 实验评估：周期分析




## 实验评估：可扩展性

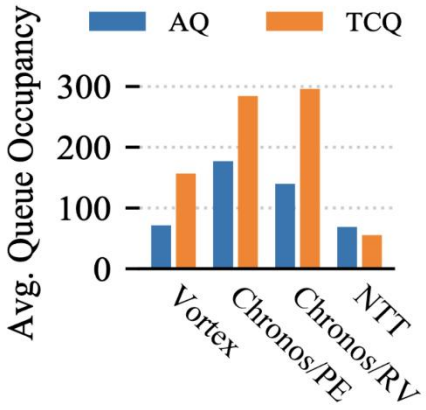


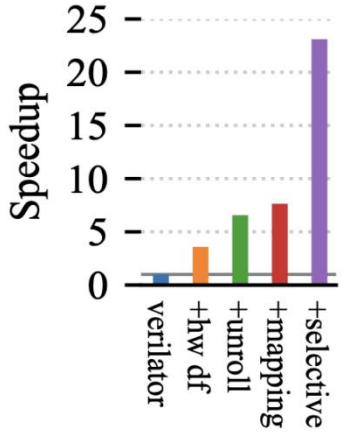

## 实验评估：能耗分析



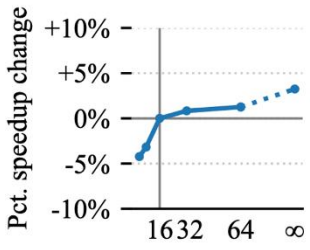
# 案例二

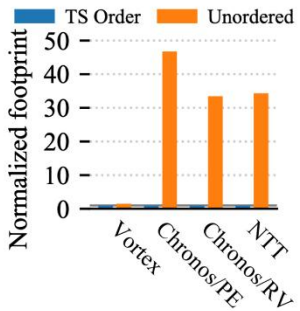
## 实验评估：ASH特性

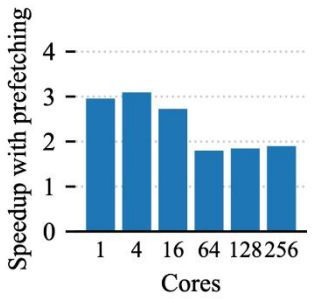



## 实验评估：ASH特性




**研究结论和思考是对论文原文的翻译，缺少总结和思辨性。**

# 结论

- 本文贡献
  - 硬件：硬件支持数据流执行和选择性执行。
  - 软件：编译器优化。
  - 实验结果：ASH系统显著加速RTL仿真。
- 思考
  - ASH系统软硬件实现复杂。
  - 缺乏硬件验证。

# 问题在哪?

**六不选** 不选本人成果；不选早期文章；不选综述文章
不选技术标准；不选宏观方案；不选实验统计

- **现场情况：**

**汇报时间，14:40-14:55，报告时间15分钟，报告后无质疑学生提问交流。**

- **原因**

**论文选题偏宏观方案，缺少核心算法、基本原理部分，难进行熵减、思辨。**





# 目　录


01 选题来源

02 负面案例

03 正面案例

04 选题建议

# 方班研讨厅选题关键

**五选**

1、锁定所从事方向持续跟进：导师主导，按照课题组的要求选择；
2、研习本领域中有代表性的文章：方向确定，从核心方法入手；
3、关注兴趣方向以求探索：方向不确定，从已有基础的角度出发；
4、关注热点以寻找机会：方向不确定，跟随热点来快速进入角色；
5、选择系统性分析的文章：从经典文章入手来学习写文章的方法。

# 案例三： 关注热点及需求点

| 八期学生 | 论文题目 | 主题 |
| --- | --- | --- |
| 陈泽涛 | ShieldVLM：基于 LVLMs 审慎推理的**多模态隐性毒性防护** | 人工智能安全 |
| 陈泽涛 | Con Instruction:多模态大语言模型的通用**非文本模态越狱** | |
| 陈景超 | 通过反向传播语言模型反馈来优化生成式 AI | |
| 陈景超 | 针对文本到图像模型的感知引导**越狱攻击** | |
| 熊佳旖 | 基于多模态大语言模型的**零样本异常检测与推理** | |
| 黄易 | SS-GEN:基于大语言模型的社会故事生成框架 | |
| 黄易 | JailPO:一种通过偏好优化对抗对齐大语言模型的新型**黑盒越狱框架** | |
| 许刚 | PLeak：针对大语言模型应用的**提示泄露攻击** | |
| 张伟男 | 愚弄傻子：利用**分布外策略越狱** LLM 和多模态 LLM | |

广州大学齐佳音教授团队聚焦大模型安全、越狱攻击与安全防护等研究。

# 案例三： 关注热点及需求点




提出了一种针对大语言模型应用的**自动化提示泄露攻击方法。**

**核心：** 通过梯度搜索生成对抗性查询，显著提升了攻击效果。

# 案例三：

**PPT总计29页、包括四个部分。**

5~7分钟

研究背景
与问题相关的背景

问题描述
核心技术问题是什么?

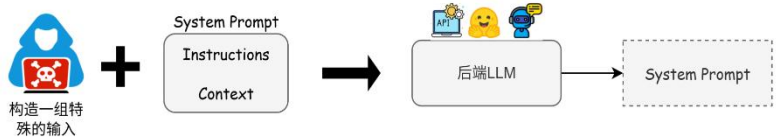
动机目标
技术创新的目标




## 1.3 提示泄露与威胁模型

**提示泄露** (Prompt Leaking):

是指攻击者通过构造特殊输入，诱导模型暴露部分或全部原始系统提示的攻击行为。




**威胁模型**

- 攻击目标： LLM 应用 (如 Poe 上的 Bot)。
- 攻击对象： 应用内部保密的系统提示 ( $p_t$ )。
- 攻击者能力：
  - 黑盒访问目标 LLM 应用，发送查询并接收响应
  - 白盒访问影子 LLM 和系统提示数据集 ( $D_s$ )
- 攻击者限制： 无法访问 LLM 内部架构或参数，无法修改模型权重。









## 1.5 本文工作

- 本文首次提出了一个自动化、闭盒的提示泄露攻击框架 —— PLeak
  - 优化对抗性查询（Adversarial Query, AQ）： 将寻找对抗性查询形式化为一个优化问题，并使用梯度近似的方法求解。
  - 关键技术：
    - 增量搜索（Incremental Search）： 采用由短至长的策略逐步重构系统提示，避免优化陷入局部最优。
    - 后处理（Post-processing）： 聚合多次攻击的响应，通过提取重叠句子片段，有效重构完整提示。
  - 对抗性转换（Adversarial Transformation）： 应对基于过滤的防御机制，通过转换系统提示的泄露形式来规避检测。

# 案例三：

**逻辑清晰、重点介绍了论文中的框架和方法。**

核心算法
围绕技术创新展开

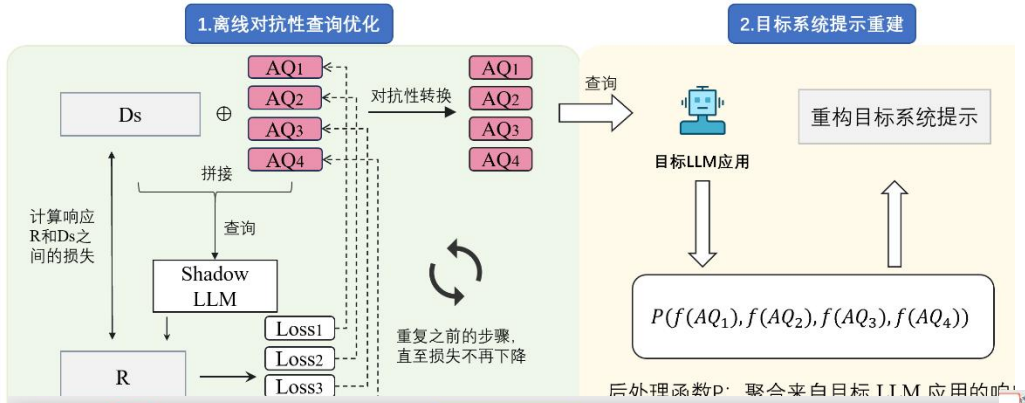
基本原理
建立完整技术视图

背景知识
基本概念、理论

13~15分钟



## 2.1 PLeak框架概述






## 2.2 对抗目标形式化

- **核心目标：**找到一个AQ（$q_{adv}$），当它被发送到目标 LLM 应用时，使其响应能最大化泄露出该应用的系统提示。
- **形式化表示：**
  - 给定连接 $e \oplus e_{adv}$ 作为输入，影子 LLM 输出 $e$ 作为响应的概率可以计算如下：

$$\Pr(\mathbf{e}|\mathbf{e} \oplus \mathbf{e}_{\text{adv}}) = \prod_{i=1}^{n_e} \Pr(e_i|\mathbf{e} \oplus \mathbf{e}_{\text{adv}}, e_1, e_2, ..., e_{i-1})$$

$$\mathcal{L}(\mathbf{e}_{\text{adv}}) = -\sum_{\mathbf{e} \in D_s} \frac{1}{n_e} log \prod_{i=1}^{n_e} \Pr(e_i|\mathbf{e} \oplus \mathbf{e}_{\text{adv}}, e_1, ...e_{i-1})$$

$$\min \mathcal{L}(\mathbf{e}_{\text{adv}})$$



## 2.4 梯度近似

**将问题分解：**对$e_{adv}$中的每个嵌入向量进行近似计算，逐token的进行优化。定义 $e_{adv}$ 中第 $j$ 个嵌入向量 $e_{adv_j}$ 的损失函数：

$$\mathcal{L}(e_{\text{adv}_j}, t) = \mathcal{L}(\mathbf{e}_{\text{adv}}, t)$$

**梯度近似：**更新第 $j$ 个嵌入向量时，将$e_{adv}$中的$e_{adv_j}$替换为$e'_{adv_j}$，将新的AQ记为$e'_{adv}$，此时：

$$\mathcal{L}(e'_{\text{adv}_j}, t) = \mathcal{L}(e_{\text{adv}_j}, t) + [e'_{\text{adv}_j} - e_{\text{adv}_j}]\nabla_{e_{\text{adv}_j}} \mathcal{L}(e_{\text{adv}_j}, t)$$

一阶泰勒展

因此，可以通过以下优化问题来确定第 $j$ 个嵌入向量：

$$\min_{e'_{\text{adv}_j} \in W} e'_{\text{adv}_j} \nabla_{e_{\text{adv}_j}} \mathcal{L}(e_{\text{adv}_j}, t)$$

在嵌入向量集合$W$中进行搜索，找到使上述目标函数最小的嵌入向量$e'_{adv_j}$

为避免次优，保留使目标函数最小的前 k 个嵌入，并从中选择使真实损失函数最小的嵌入向量作为$e'_{adv_j}$





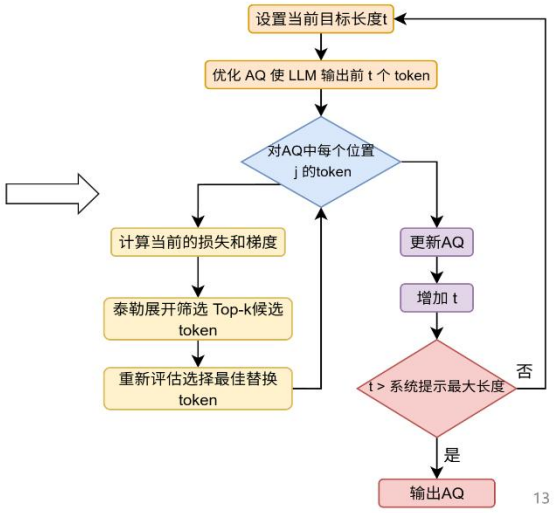
## 2.5 增量搜索

**Algorithm 1** incrementSearch

**Input:** Adversarial query length $m$, shadow dataset $D_s$, step size $s$, and all token embeddings $\mathcal{W}$.
**Output:** AQ $q_{\text{adv}}$.
1: Initialize $q_{\text{adv}}$ with $m$ tokens
2: length ← max(length of each shadow system prompt in $D_s$)
3: **for** $i = 1, 2, ..., \lceil \text{length}/s \rceil$ **do**
4: $t \leftarrow i * s$
5: $q_{\text{adv}} \leftarrow \text{generateAQ}(D_s, q_{\text{adv}}, t, \mathcal{W})$
6: **return** $q_{\text{adv}}$

从 t = s (步长) 开始，逐步增加 t（t = s, 2s, 3s, ...），直到覆盖影子数据集中最长的提示。

- 输入：AQ的长度m，影子数据集Ds，步长s，token嵌入集合 $W$
- 输出：优化后的AQ




- 这种策略在处理长系统提示时表现出显著优势，避免了优化过程陷入局部最优，并最大化了泄露信息的量。

# 案例三：

**讲清楚了实验设置，并做了性能分析、参数分析和效果分析。**

实验方法
实验设计、数据

结果分析
结合技术创新解读

总结展望
提出学术观点

2~4分钟

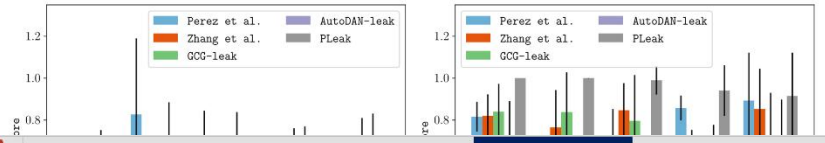


## 3.1实验设置

| 数据集名称 | 说明 |
| --- | --- |
| ChatGPT-Roles | 角色扮演指令 |

汇报进程 | 背景介绍 | 方法介绍 | 实验分析 | 总结与思考

## 3.2 提示泄露攻击性能




汇报进程 | 背景介绍 | 方法介绍 | 实验分析 | 总结与思考

## 3.6 可迁移性

关注点： 跨 LLM（不同模型架构）、跨数据集（不同任务领域）。
AQ 的通用性： 验证优化后的 AQ 能否在不同 LLM 或不同数据领域的目标应用上依然有效。

| Model | SM(↑) | EM(↑) | EED(↓) | SS(↑) |
| --- | --- | --- | --- | --- |
| GPT-J | 0.917 | 0.903 | 0.067 | 0.923 |
| OPT | **1.0** | **1.0** | **0.005** | **0.995** |
| Falcon | 0.953 | 0.933 | 0.042 | 0.957 |

由LLaMA-2优化生成的AQ在GPT-J, OPT, Falcon上的SM和EM分数均高于0.9，尤其在OPT上达到1.0，表明PLeak 生成的AQ具有很强的跨LLM迁移性。

| Dataset | Financial | Tomatoes | Roles | SQuAD | SIQA |
| --- | --- | --- | --- | --- | --- |
| Financial | - | **0.995** | 0.758 | 0.389 | 0.432 |
| Tomatoes | **0.993** | - | 0.529 | 0.241 | 0.233 |
| Roles | **0.996** | 0.992 | - | **0.996** | 0.982 |
| SQuAD | **0.905** | 0.886 | 0.725 | - | 0.725 |
| SIQA | 0.972 | 0.987 | **0.994** | 0.958 | - |

PLeak生成的AQ在跨不同数据集时也展现出一定的迁移性。例如，在Tomatoes 数据集上生成的AQ在Financial 数据集上获得了0.995的SM分数。



汇报进程 | 背景介绍 | 方法介绍 | 实验分析 | 总结与思考

## 3.1实验设置

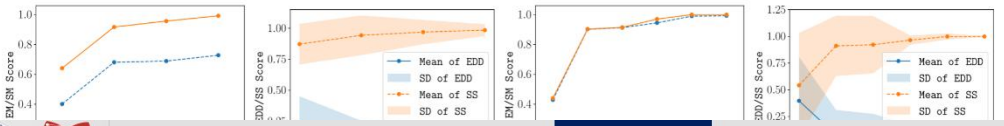
**目标 LLM 应用：** 离线 LLM 应用 / 现实世界 LLM 应用

**Baseline**

**评估指标**

汇报进程 | 背景介绍 | 方法介绍 | 实验分析 | 总结与思考

## 3.4 参数分析




汇报进程 | 背景介绍 | 方法介绍 | 实验分析 | 总结与思考

## 3.7 PLeak对潜在防御的效果

系统提示增强防御下的 SM 表现 (SIQA)

| Method | Parameterization | Quotes |
| --- | --- | --- |
| Perez et al. | 0.008 | 0.000 |
| Zhang et al. | 0.244 | 0.029 |
| GCG-leak | 0.014 | 0.012 |
| AutoDAN-leak | 0.043 | 0.022 |
| PLeak | **0.906** | **0.485** |

基于过滤防御下的真实世界攻击表现 (Poe)

| method | SM(↑) | EM(↑) | EED(↓) | SS(↑) |
| --- | --- | --- | --- | --- |
| Perez et al. | 0.040 | 0.000 | 0.498 | 0.623 |
| Zhang et al. | 0.100 | 0.000 | 0.488 | 0.669 |
| GCG-leak | 0.020 | 0.000 | 0.701 | 0.097 |
| Auto-DAN | 0.020 | 0.000 | 0.602 | 0.510 |
| PLeak | **0.340** | **0.300** | **0.230** | **0.882** |

- Parameterization 参数化：即添加忽略与提示泄露相关的提示的指令。
- Quotes 引用和格式化：即引用系统提示以防止泄露。

**结论：**

➢PLeak 在应对系统提示增强防御时表现出很强的鲁棒性，明显优于现有基线方法。

➢PLeak 在部署了过滤防御的情况下，依然优于现有基线方法，成功泄露和重构系统提示，这主要得益于其采用了对抗性转换策略，能够绕过基于内容的过滤。

# 案例三：

**较好的总结了论文的创新和局限性，不足之处是缺乏思辨性。**



## 4.1 论文的优点和创新之处

开创性工作：PLeak 是首个自动化的提示泄露攻击框架，将复杂的提示泄露问题转化为可优化的数学问题。

有效性极高： PLEAK 在 Poe 平台上的50个真实 LLM 应用中进行了测试，结果显示 PLEAK 能够成功泄露68%的系统提示，显著优于基于手工编写和现有优化查询的攻击方法。

**核心方法的创新**

- **增量搜索**：精妙地利用 LLM 的自回归特性，将复杂问题分解为可管理的步骤，有效解决了长系统提示的精确匹配难题。
- **梯度优化与Top-k选择**： 结合梯度近似和真实损失评估，克服了离散空间搜索的挑战，提高了优化效率和准确性。
- **后处理机制**： 通过聚合多个响应来提高攻击鲁棒性和完整性，有效弥补单个查询的不足。
- **对抗性转换**： 预见性地考虑了防御措施，并提出了有效的规避策略，增强了攻击的实用性。





## 4.2 论文的局限性

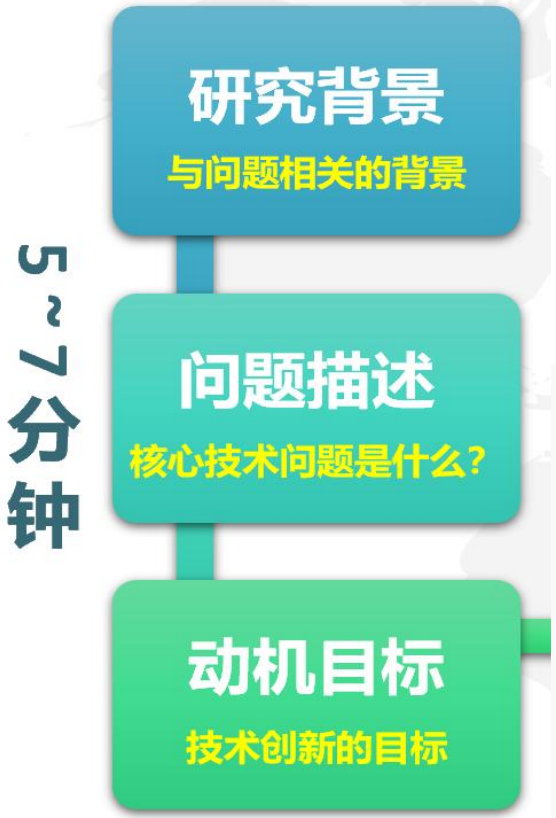
**局限**

- **真实世界攻击部署的验证：** 目前 PLeak 在实际“未知”攻击场景中，攻击者难以确切判断是否成功泄露了完整且正确的系统提示。
- **计算资源消耗：** 优化对抗性查询需要大量计算资源（如本文使用了4张 A100 GPU显卡）。
- **转换策略的通用性：** 对抗性转换（如添加前缀、反转词序）虽然有效，但其设计仍可能依赖于对防御机制的猜测，若防御机制更智能，可能会有新的规避挑战。
- **闭盒模型假设：** 攻击者无法访问内部LLM架构或参数，但其优化过程仍需要一个“影子LLM”，这需要攻击者有能力部署或访问与目标LLM有一定相似性的模型。当影子LLM与目标LLM差异很大时，迁移性会受到影响（如GPT-J生成AQ在Falcon上SM降至0.634）。

# 案例三

- **现场情况：**

**汇报时间，18:00-18:24，报告时间24分钟，报告后9名质疑学生提问交流。**











# 目　录


01 选题来源

02 负面案例

03 正面案例

04 选题建议

# 选题三点建议

**目标：为未来的研究做准备，从兴趣走向学术价值。**

**通过选择的论文进行研读汇报，把握研究前沿，掌握研究方法！**

**建议1：** 论文选择与辅导老师的研究方向匹配。

**建议2：** 三次研讨厅汇报论文沿着一个主题方向。

**建议3：** 充分利用方班课程资料数据库。

# 一、论文选择与辅导老师的研究方向匹配

**优势：辅导老师可以充分指导，组内同学研究方向一致，可以交流讨论。**

| 学生 | 论文题目 | 主题 | 来源 |
|---|---|---|---|
| 七期吴方宇 | SNIFFER Multimodal Large Language Model for Explainable Out-of-Context **Misinformation Detection** | 信息与内容安全 | 2024CVPR |
| 七期吴方宇 | VMID: A Multimodal Fusion LLM Framework for **Detecting and Identifying Misinformation** of Short Videos | | 2024CVPR |
| 七期关梓聪 | Msynfd: Multi-hop syntax aware **fake news detection** | | *ACM web* |
| 七期关梓聪 | Unveiling opinion evolution via prompting and diffusion for short video **fake news detection** | | 2024ACL |
| 七期李欣频 | Forensics Adapter: Adapting CLIP for Generalizable **Face Forgery Detection** | | 2025CVPR |
| 七期李欣频 | Fake News in Sheep's Clothing: Robust **Fake News Detection** Against LLM-Empowered Style Attacks | | 2024ACM SIGKDD |

**围绕虚假信息、假新闻检测**

# 一、论文选择与辅导老师的研究方向匹配。

| 学生 | 论文题目 | 主题 | 来源 |
| --- | --- | --- | --- |
| 八期余国锋 | Double Face: Leveraging User Intelligence to **Characterize and Recognize AI-synthesized Faces** | 信息与内容安全 | 2024USENIX Security |
| 八期余国锋 | {VoiceWukong}: Benchmarking **Deepfake Voice Detection** | | 2025USENIX Security |
| 八期宋佳坤 | Leveraging Exposure Networks for **Detecting Fake News Sources** | | 2024ACM SIGKDD |
| 八期宋佳坤 | Domain-Aware Multimodal Multi-view **Fake News Detection** | | 2025AAAI |
| 八期杨溥坤 | RaCMC: Residual-Aware Compensation Network with Multi-Granularity Constraints for **Fake News Detection** | | 2025AAAI |
| 八期杨溥坤 | External Reliable Information-enhanced Multimodal Contrastive Learning for **Fake News Detection** | | 2025AAAI |

**围绕虚假信息、假新闻检测**

# 二、3次研讨厅汇报论文沿着一个主题方向

**优势：掌握选题研究脉络，理解研究方法，为提出新问题，开展研究工作做准备。**










**学生三次报告论文主题围绕基于大语言模型及错误信息检测**

# 三、充分利用方班课程数据库（fangban.net）

黄埔班　　检索同一研究方向主题已汇报论文，阅读其他同学汇报，形成跨组交流。

## 研讨厅 >




黄埔班-215-5-4-陈嘉诺-注意力驱动的免微调MLL MGUI定位

演讲记录　2025-12-25




黄埔班-215-6-4-黄信凯-DecoyPot：一种基于大语言模型的...

演讲记录　2025-12-25




黄埔班-215-7-4-郑仕榕-从风险到弹性 对联邦学习中数据重构攻击风险...

演讲记录　2025-12-25




黄埔班-215-9-4-邓宇航-GENIUS—种通用的多模态生成式检索框架

演讲记录　2025-12-25




黄埔班-215-8-4-刘婷玉-评估和利用用于自动化渗透测试的大型语言模型

演讲记录　2025-12-25

## 演武堂 >




黄埔班-106-6-2-刘慧婷-LLaMA-Factory

演讲记录　2025-12-31




黄埔班-106-6-1-江晓艺-arthas

演讲记录　2025-12-31




黄埔班-106-7-3-陈家豪-PocketFlow

演讲记录　2025-12-31




黄埔班-106-7-2-鹿艺潇-CobaltStrike Payload免杀工具设...

演讲记录　2025-12-31




黄埔班-106-7-1-游俊爽-基于MCP协议的网络安全日志智能分析工具设...

演讲记录　2025-12-31

## 前沿秀 >



方班前沿秀第四十二期：华南理工大学陈俊龙教授做“基于宽度学习的隐...

上课演讲稿　2025-12-27




方班前沿秀第四十一期：同济大学申恒涛教授作“面向空间、任务、本体...

上课演讲稿　2025-12-24



方班前沿秀第四十期：浙江大学博导闫琛博士做关于“你的设备我做主...

上课演讲稿　2025-11-16



方班前沿秀第三十九期：澳门城市大学朱天清教授做关于“LLMs的双面...

上课演讲稿　2025-11-01



方班前沿秀第三十八期：香港科技大学（广州）陈雷教授做关于“数据科...

上课演讲稿　2025-10-27

# 三、充分利用方班课程数据库（fangban.net）

教学动态

- 黄埔班研讨厅
- 黄埔班演武堂
- 示范班研讨厅
  - 上课新闻稿
  - 演讲记录
- 黄埔班前沿秀
- 典型案例

演讲记录

搜索关键字



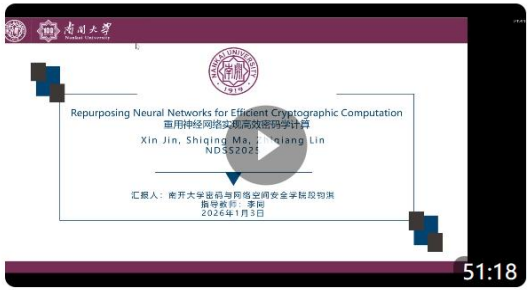

示范班-143-7-2-武汉大学-谢子洋-从约束到漏洞：将约束语义不一致作为...

2026-01-08




示范班-143-6-4-山东大学-曹海健-通过 SMPC 对 Transformer 模型进行...

2026-01-08




示范班-143-6-3-南开大学-段钧淇-重用神经网络实现高效密码学计算

2026-01-08




示范班-143-6-2-华中科技大学-曾珺-面向Java程序本地代码解析的交互式...

2026-01-08




示范班-143-6-1-华中科技大学-欧阳俨茁-VulShied：在部署补丁前保护...

2026-01-08




示范班-145-5-4-北京理工大学-周锦鑫-ChatTS

2026-01-08

# 三、充分利用方班课程数据库




汇报人：李靖韬

指导老师：李树栋

汇报日期：2025.05.20

博学笃行 与时俱进

广州大学



# 三、充分利用方班课程数据库






# 总结

**论文选题和选择很重要，能力培养更重要！！！**

**文献调研、阅读论文、复现论文、讲述论文、发现问题+解决问题**



**知识储备、理解能力、代码能力、表达能力、创新能力**

**求源、熵减、思辨**


广州大学
GUANGZHOU UNIVERSITY

广州大学网络空间安全学院
CIAT
Cyberspace Institute of Advanced Technology


# 谢 谢!