Feature Distillation is the Better Choice for Model-Heterogeneous Federated Learning

Yichen Li, Xiuying Wang, Wenchao Xu Haozhao Wang, Yining Qi, Jiahua Dong, Ruixuan Li
School of Computer Science and Technology,
Huazhong University of Science and Technology, Wuhan, China
Mohamed bin Zayed University of Artificial Intelligence, Abu Dhabi, United Arab Emirates
International School, Beijing University of Posts and Telecommunications, Beijing, China
Department of Computing, The Hong Kong Polytechnic University, Hong Kong, China
{ycli0204,hz_wang}@hust.edu.cn, leowang980@bupt.edu.cn

摘要：

模型异构联邦学习（Hetero-FL）能够在本地私有数据不泄露的前提下，聚合异构模型的知识，因此受到越来越多的关注。为了更好地聚合客户端知识，集成蒸馏作为一种高效通用的技术，常被用于全局聚合后提升全局模型性能。但直接将异构联邦学习与集成蒸馏结合往往效果不佳，还会造成训练过程不稳定。根源在于现有方法大多依赖逻辑输出蒸馏(logit 蒸馏)：该方法虽与模型结构无关、仅依靠 Softmax 预测值，但无法消除异构模型带来的知识偏差。

针对该问题，本文提出一种稳定高效、面向模型异构联邦学习的特征蒸馏方案 FedFD。该方法通过正交投影实现特征对齐，从而更好地融合异构模型的知识。具体来说，本文构建一套全新的基于特征的集成联邦知识蒸馏范式：服务器侧的全局模型为每一类客户端模型架构单独维护一层投影层，分别完成特征对齐；并利用正交化技术对投影层重新参数化，缓解异构模型带来的知识偏差，最大化

可迁移蒸馏知识。

在多组实验设置下的大量对比实验证明, FedFD 相比现有主流算法能够取得更优的模型性能。

1.引言

联邦学习（FL）是一种分布式协同训练神经网络的核心框架，全程保护各客户端本地数据隐私 [34,50,29]，目前已广泛落地于自动驾驶 [32,37]、推荐系统 [27,26]、智能医疗 [7,40] 等领域。

传统联邦学习研究大多聚焦同构模型场景。但随着物联网设备普及，不同终端设备算力、模型训练能力差异巨大 [39,31]，因此亟需研究模型异构联邦学习（Hetero-FL），充分利用分布式设备的计算资源。该场景下最核心的难点是：如何有效融合不同结构模型输出的知识。

知识蒸馏 [15] 是解决该问题的主流方案，核心思路是将多个本地模型的输出软预测融合，再迁移至全局模型。已有相关工作：文献 [52] 提出直接聚合模型逻辑输出而非参数；文献 [21] 利用聚合后的类别得分约束本地训练；基于文献 [6] 提出的局部参数聚合思路，大量工作采用集成蒸馏优化全局模型，如 [33,49]；[48,55] 基于逻辑蒸馏做知识筛选优化聚合效果；[43] 从本地模型与集成预测中筛选精准可靠的知识。

尽管上述工作将集成蒸馏与异构联邦学习结合后取得了一定性能提升，但逻辑蒸馏在异构联邦场景下的内在缺陷仍未被充分探究：

在客户端模型结构完全一致的同构联邦学习中，借助分布近似的公共代理数据集，逻辑蒸馏可以完美抵消数据异构带来的类别概率分布偏移 [46]。但模型

异构场景下的核心矛盾是不同模型生成的隐层特征表征空间完全不同，逻辑输出蒸馏对此束手无策。不同结构的模型会将同一份样本映射至完全不同的特征空间，最终输出的 Softmax 逻辑值差异极大 [10]。逻辑表征仅关注模型输出层，无法对齐异构模型的隐层特征空间，直接导致蒸馏效果大幅衰减。

本文采用 t-SNE 可视化 CIFAR-10 数据集上客户端异构模型的集成知识表征（见图 1）：对比本文提出的特征表征，聚合逻辑输出的表征分类边界模糊，说明作为教师模型的集成知识质量较差。同时我们通过实验验证：逻辑蒸馏会造成联邦训练震荡，直接聚合逻辑值作为教师监督信号并不稳定，相关实验见 3.2 节。

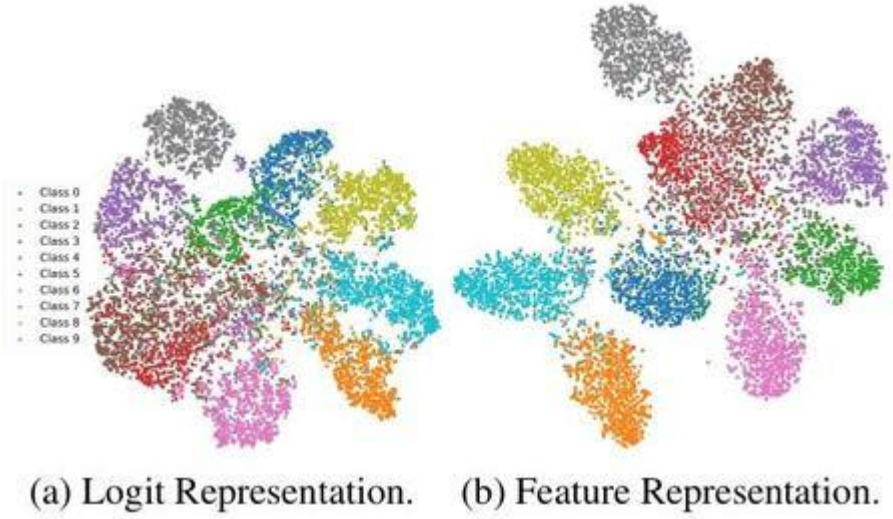


图 1 CIFAR-10 数据集上异构模型集成知识表征的 t-SNE 可视化
(a) 逻辑输出表征 (b) 特征表征

为突破对数似然蒸馏在异构模型联邦蒸馏（FD）场景下存在的局限性，本文探究特征蒸馏方案，用以整合经蒸馏得到的知识；而特征表征与模型结构有着极强的关联性。

在异构联邦学习（Hetero-FL）中利用特征表征开展集成蒸馏面临着全新挑战：在中心化学习环境里，特征知识通常借助外部投影层，从规模更大的模型（教师模型）蒸馏至小规模模型（学生模型）[41,35]。这与异构联邦学习的情况截然

不同 —— 异构联邦学习中，各客户端的小型模型往往需要将自身知识经过集成蒸馏后传递给服务端的大型模型，且不同客户端模型的网络结构互不相同。因此，如何合理设计投影层的使用方式、实现不同客户端模型特征表征的对齐，成为异构联邦学习集成蒸馏亟待解决的核心难题。

围绕上述研究思路，本文提出一种适配异构联邦学习、稳定且高效的特征蒸馏方法 FedFD。该方法借助正交投影完成特征表征对齐，以此削弱由异构模型聚合所带来的知识偏差。具体而言：针对每一条待蒸馏样本，各客户端先提取自身的特征表征；服务端会先对具有相同网络结构的客户端模型输出特征表征进行聚合，形成由多种模型架构聚合特征构成的特征簇。对于特征簇内的每一份特征表征，服务端需要训练对应的投影层，让服务端模型提取出的特征表征与该特征完成对齐，同时联合优化投影层参数以及服务端模型特征提取器的参数。除此之外，为避免聚合后的各类特征表征之间产生知识偏差，本文引入正交投影技术，尽可能最大化可迁移的知识量。

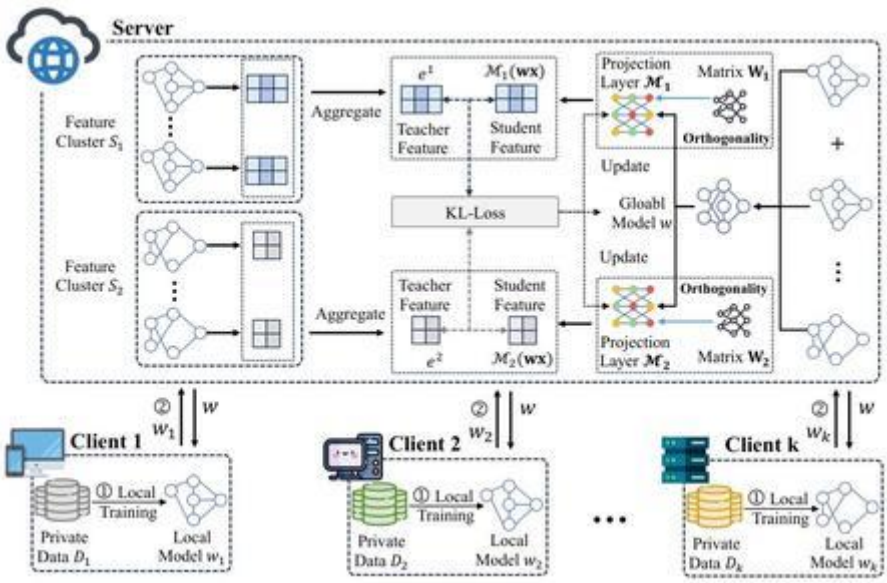


图 2 FedFD 整体框架

蒸馏流程前，各客户端先基于本地私有数据集完成本地训练，再将本地模型上传至服务器；服务器聚合所有本地模型得到初始全局模型。蒸馏阶段分层完成特征对齐：首先聚合

相同架构客户端模型输出的特征表征；随后为每一类聚合特征配备独立投影层，该投影层通过方阵正交变换得到；最终通过 KL 散度分别对齐不同架构模型的特征表征，完成特征蒸馏。

本文在三个数据集、多种实验设置（涵盖不同模型结构与数据分布）上开展了大量实验，结果表明：相较于当前最优算法，本文提出的框架能够显著提升模型精度。本文主要研究贡献如下：

- 本文对模型无关的联邦知识蒸馏展开了深入分析，发现现有方法大多依赖对数输出（logit）蒸馏；当模型存在异构差异时，这类方法会造成蒸馏得到的知识表征出现偏差误导，带来严峻挑战。
- 本文提出了名为 FedFD 的全新框架，该框架可直接作为异构联邦学习（Hetero-FL）的通用个性化拓展模块，同时延续了传统知识蒸馏方法在隐私保护与计算效率方面的优良特性。
- 本文在多类数据集、多种实验配置下完成了充分的对比实验。实验数据证明：在各类下游任务的测试精度指标上，本文提出的模型性能相比现有前沿方法最高可提升 16.09%。

2 相关工作

联邦学习通过聚合多客户端本地训练模型，协同训练统一全局模型，全程保护本地数据隐私 [25,47,28,30]。经典基线 FedAvg [34] 通过平均本地模型参数更新全局模型；FedProx [23] 引入近端项缓解跨设备数据分布异构带来的负面影响。上述方法均假设所有客户端模型结构完全一致；文献 [6] 首次提出异构联邦学习，允许不同算力客户端训练复杂度不同的本地模型；文献 [51] 通过网络宽度、深度灵活调整，结合跳跃连接、结构化剪枝实现模型异构；文献 [17] 针对 VGG 等网络，提取客户端网络公共层聚合，适配不同深度的异构模型。本文聚焦异构客户端场景，基于知识蒸馏技术优化全局知识融合效果。

知识蒸馏利用预训练模型蕴含的知识来监督小规模模型训练，从而助力该轻量化模型在资源受限环境下落地应用与部署 [14]。该研究方向主要分为两大分支：对数输出（logits）蒸馏 [38,18,1,16] 与特征蒸馏 [44,36,13,5]。对数输出蒸馏主要面向分类任务，额外增设一项优化目标，以缩小学生模型与教师模型的预测输出差异；这类方法最初采用 KL 散度实现优化 [14]，后续研究又通过球面归一化 [8]、标签解耦 [57]、概率重加权 [38] 等方式对其进行拓展完善。由于特征蒸馏能够适配多种任务 [5] 与数据模态 [42]，适用范围更广，因此本文研究以特征蒸馏为核心方向。FSP 矩阵是一种人工设计的结构，用于提取残差层之间的特征关联信息 [54]；除此之外，也有其他研究提出借助格拉姆（Gram）矩阵完成知识迁移 [24]。另有研究表明，激活边界以及刻画损失曲面的梯度信息同样可以作为有效的蒸馏监督信号 [44]。本文重点研究结合正交投影与集成蒸馏方式实现联邦蒸馏（FD）中的特征蒸馏技术。

联邦蒸馏的思路是从多名由不同客户端各自训练得到的教师模型中提取知识，并将这些知识迁移至一个学生模型当中 [53,9,2]。文献 [33] 首次提出在服务器端架构中引入知识蒸馏思路，借助无标签代理数据集，将各客户端本地模型的知识迁移至全局模型。文献 [4] 在此基础上进一步优化：基于贝叶斯后验计算对应权重，对多个本地模型做线性聚合，生成若干组合模型，再将这些组合模型的知识蒸馏整合至单一全局模型。为摆脱对无标签辅助数据集的依赖，文献 [58,56,49] 提出利用生成模型合成数据来替代代理数据集，在无需真实原始数据的前提下即可完成蒸馏流程。本文分析了现有联邦蒸馏（FD）方法在异构模型联邦学习（FL）场景落地时面临的难点，并提出改用特征蒸馏方案，而非传统对数输出蒸馏方案。

3 方法

本节首先形式化定义同构 / 异构联邦学习标准流程；随后通过实验分析逻辑蒸馏在异构联邦学习中的失效原因；最后详细介绍本文提出的特征蒸馏方案 FedFD。FedFD 完整流程见算法 1，整体框架见图 2。

3.1 问题形式化

典型的联邦学习（FL）问题可形式化为：为联邦学习中总共 K 个客户端协同训练一个全局模型。我们假设第 k 个客户端仅能访问其本地私有数据集 $D_k=\{x_k^{(i)},y_k^{(i)}\}$，其中$x_k^{(i)}$是第 i 条输入样本，$y_k^{(i)}\in\{1,2,\cdots,C\}$是$x_k^{(i)}$对应的标签，类别总数为 C。记数据集$D_k$内样本数量为$|D_k|$。联邦学习系统的优化目标是学习全局模型参数 w，使得在全体数据集 D 上的总体经验损失最小：

$$\min_w \mathcal{L}(w)=\sum_{k=1}^{K}\frac{|D_k|}{|D|}\mathcal{L}_k(w),$$

其中

$$\mathcal{L}_k(w)=\frac{1}{|D_k|}\sum_{i=1}^{|D_k|}\mathcal{L}_{CE}(w;x_i^k,y_i^k), \qquad (1)$$

式中$\mathcal{L}_k(w)$代表第 k 个客户端的本地损失，$\mathcal{L}_{CE}$为交叉熵损失函数，用于衡量模型预测结果与真实标签之间的偏差。对于同构模型，服务端只需对各客户端本地模型参数做加权平均即可得到全局模型，更新公式如下：

$$w:=\sum_{k=1}^{K}\frac{|D_k|}{|D|}\cdot w_k. \qquad (2)$$

而对于异构模型，本文沿用文献 [6] 提出的方案，假设所有客户端模型可被划分为 p 种不同的架构集合$\{S_1,S_2,\cdots,S_p\}$。随后按照如下方式执行全局聚合操作：

$$w_p^s = \sum_{w_i \in S_p} \frac{w_i}{|S_p|}, \quad w_{p-1}^s \backslash w_p^s = \frac{1}{K - |S_p|} \sum_{w_i \in S_p} w^{s}_{p-1} \backslash w_p^s,$$

$$w = w_p^s \cup (w_{p-1}^s \backslash w_p^s), \mathrm{dots}, \cup (w_1^s \backslash w_2^s). \quad (3)$$

式中w_p^s表示客户端第 p 类架构模型聚合后得到的模型。为简化符号书写，公式 (3) 省略了训练轮次下标，同时简化了每一个待聚合客户端模型的权重；在常规实现中，该权重通常会按照各客户端样本数量占比进行加权计算。

3.2 逻辑蒸馏在异构联邦学习中失效

在现有的联邦学习方法中，核心技术是利用模型在蒸馏数据集上的软预测结果（对数输出 logits），将教师模型中的知识迁移至学生模型。此处教师模型的预测结果由多个客户端输出的对数输出聚合得到，该方式在联邦学习领域也被称作集成蒸馏。该技术在同构联邦学习（面向同构模型）中能够发挥作用：由于所有客户端模型结构完全相同，这类模型输出的对数输出不会产生因模型结构差异带来的偏差，还能在一定程度上缓解数据异构带来的问题。但如果直接将这种对数输出蒸馏技术应用于异构联邦学习（面向异构模型）则并不合适，目前相关现有研究也尚未探讨：来自不同客户端模型架构输出的对数输出，能否直接聚合来充当教师模型的预测结果。基于图 1，我们开展了进一步实验。本文选取了几种鲁棒性较强的集成蒸馏算法，分别在同构联邦学习、异构联邦学习两种实验配置下，基于 CIFAR-10 数据集完成测试。这些方法的详细介绍将在 4.1 节展开，对应的学习曲线绘制在图 3 中。

在同构联邦学习的实验条件下，所有方法都可以快速且稳定地收敛，印证了对数输出蒸馏方法的有效性。然而切换至异构联邦学习场景后，联邦学习算法会出现训练不稳定的现象：精度曲线反复出现震荡峰值，各类算法最终都无法收敛至最优精度。尽管对数输出蒸馏能够在训练初期加快模型收敛速度，但随着本地

模型在各自本地数据集上逐步收敛，后续蒸馏过程会变得极不稳定，该现象与同构联邦学习中的实验表现截然相反。究其根源，对数输出蒸馏仅依靠模型软预测结果开展知识迁移，完全没有考虑不同客户端模型之间的结构差异。因此下文将介绍本文提出的基于特征的蒸馏方法，用以解决上述问题。

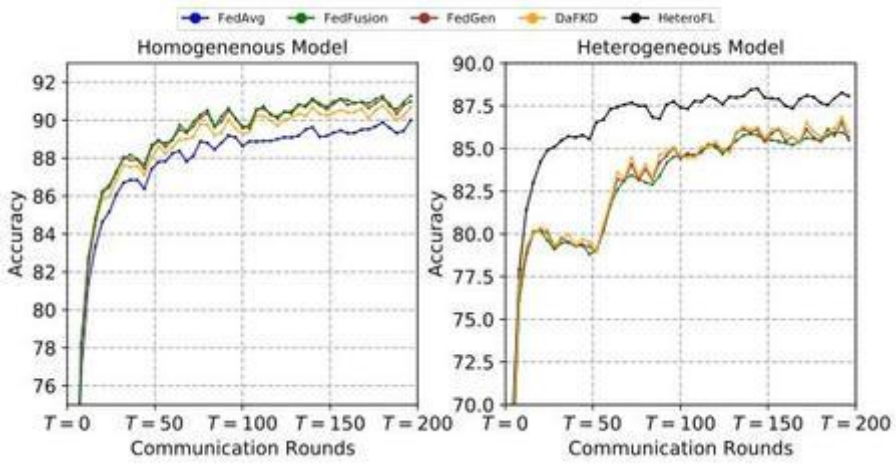


图 3 CIFAR-10 数据集上基于逻辑蒸馏的各类方法学习曲线
左：同构模型设置；右：异构模型设置

3.3 FedFD：面向异构联邦学习的特征蒸馏框架

本文旨在挖掘特征蒸馏在异构联邦学习（Hetero-FL）中的应用潜力。尽管特征蒸馏适用范围广泛，但该方法往往需要大量复杂的设计抉择与经验性调优。这些设计主要围绕中间特征表征之间的损失函数展开，会带来额外的训练开销。为解决上述缺陷，本文仅使用分类器前一阶段输出的特征表征来开展特征蒸馏。

在异构联邦学习场景中，教师模型通常由客户端多个小型模型集成输出得到，但仍需要在全局模型（学生模型）后额外添加投影层，保证蒸馏过程中知识能够经由投影层反向传播，进而更新模型参数。然而该方案存在两大难点：（1）由于客户端模型架构多种多样，若服务端为每一类客户端模型都单独维护专属投影层，会造成训练难度上升 —— 每个客户端所能贡献的知识量本身就十分有限；此外联邦学习预训练阶段参与的客户端数量通常较多，若大量投影层都需要服务端存

储，长期累积会给服务器带来极高的存储成本。(2) 不同客户端模型提取出的特征知识，在经过各自投影层映射后可能会互相冲突；强行融合这些复杂的非线性知识，也无法让全局模型的特征提取模块得到最优训练效果。

算法 1 FedFD

输入：T：通信轮次；K：客户端总数；D_k：第 k 个客户端的本地数据集；w：全局模型；w_k：客户端本地模型；$\mathcal{M}_k$：投影层；S_k：第 k 个客户端对应的模型架构；$\mathbf{W}_k$：正交性计算矩阵。

输出：$w,\{w_1,\mathrm{dots},w_k\}$：训练完成的全局模型与所有客户端本地模型。

1 for $c=1$ to T do // 单轮通信迭代

2 服务端随机选取一部分参与本轮训练的客户端子集S_t；

3 服务端将当前全局模型 w 下发至被选中的客户端设备；

4 for 每一个被选中、属于S_t的客户端 k 并行执行 do

5 根据公式 (1) 训练客户端本地模型w_k；

6 将训练后的本地模型w_k回传给服务端；

7 end for

8 $w\leftarrow$ 调用公式 (3) 对所有上传的本地模型$\{w_k\}_{k\in S_t}$执行服务端聚合；

9 利用式 (5) 计算聚合后模型输出的特征表征e^d；

10 通过式 (7) 对正交矩阵$\mathbf{W}_D$做正交化处理，得到对应的投影层$\mathcal{M}_d$；

11 利用式 (9) 将提炼得到的特征知识蒸馏迁移至全局模型；

12 end for

为解决上述问题，本文提出一种基于特征蒸馏的算法 FedFD，该方法包含两大核心模块：分层特征对齐与参数正交化。在每一轮通信训练中，参与本轮训练

的客户端 k 首先依据式 (1) 在本地完成模型w_k的训练，并将训练好的模型上传至服务器。服务器收到所有客户端上传的本地模型后，通过式 (3) 聚合得到更新后的全局模型 w。与文献 [33][49][58] 思路类似，服务器会将客户端模型学到的知识作为教师监督信号，在蒸馏数据集上对全局模型开展蒸馏训练，进一步提升全局模型性能。结合前文实验结论，本文选择直接使用特征表征完成知识蒸馏。设客户端 k 的本地模型w_k由特征提取器$\mathbf{w}_k^d$和分类头θ_k两部分构成，其中 d 代表输出特征的维度。对于任意一条用于蒸馏的样本$\mathbf{x}$，经由特征提取器$\mathbf{w}_k^d$计算得到对应的特征表征e_k^d，计算公式如下：

$$e_k^d = f(\mathbf{w}_k^d; \mathbf{x}),\ \forall k \in [1, K]. \quad (4)$$

随后，我们将特征划分为 m 个分组$\{S_{d_1}, \text{dots}, S_{d_m}\}$，其中每组$S_d = \{\mathbf{w}_1^d, \text{dots}, \mathbf{w}_k^d\}$包含所有结构相同、输出 d 维特征的特征提取器。记$|S_d|$为分组S_d内的特征数量。接下来，我们对分组S_d中全部特征表征做聚合计算：

$$e^d = \frac{1}{|S_d|} \sum_{i=1}^{|S_d|} e_i^d, \quad S_d = \left\{\mathbf{w}_1^d, ..., \mathbf{w}_{|S_d|}^d\right\}. \text{tag} 5$$

服务端不再为每个客户端单独维护投影层，仅需训练$(m-1)$个投影层$\{\mathcal{M}_2, \text{dots}, \mathcal{M}_m\}$。该设计不仅减少待训练参数量，还能保证每个投影层拥有充足的知识用于蒸馏。

但该方案仍无法消除不同模型架构带来的知识冲突，服务器依旧需要融合多个投影层输出的知识，以优化全局模型参数 w。我们将投影层$\mathcal{M}_d$处理后的知识S_d记作：

$$S_d = \mathcal{M}_d(wx) = \mathcal{M}_d Z, \quad Z = wx. \text{tag} 6$$

在知识蒸馏任务中，蒸馏样本数量越多，蒸馏效果通常越好，能更完整地覆盖训练数据中蕴含的知识。这使得矩阵 Z 为满秩矩阵；相应地S_d同样是满秩矩

阵，可视为一种非线性映射过程，会造成全局模型难以区分各类知识，进而引发知识冲突。

针对该问题，由于无法改变 Z 的知识分布，本文选择对投影层$\mathcal{M}_d$做变换，使其能够将知识 Z 映射至互不重叠的特征空间。为此，本文引入正交投影变换：该变换具备旋转不变性，既能解决知识冲突问题，又能保留原有特征形态。值得注意的是，Z 与S_d二者特征维度不同，且 Z 维度更高，因此$\mathcal{M}_d$不再是正交方阵，而是列向量相互正交的列满秩矩阵，对应斯蒂费尔流形（Stiefel 流形）上的矩阵[12]。这类矩阵具备优良的拓扑性质，能够支持梯度下降更新。

为保证$\mathcal{M}_d$列向量的正交性，现有方法包含凯莱（Cayley）变换 [3]、格拉姆 - 施密特正交化等，但这类方法时间开销相对较高。本文提出利用斜对称矩阵$\mathbf{W}_d$生成$\mathcal{M}_d$，推导公式如下：

$$\exp(\mathbf{W}_d)\cdot\exp(\mathbf{W}_d)^T=\exp(\mathbf{W}_d+\mathbf{W}_d^T)=\exp(-\mathbf{W}_d^T+\mathbf{W}_d^T)=\mathbf{I}.\tag{7}$$

$$\exp(\mathbf{W}_d)=\mathbf{I}+\mathbf{W}_d+\frac{\mathbf{W}_d^2}{2!}+\frac{\mathbf{W}_d^3}{3!}+\cdots+\frac{\mathbf{W}_d^n}{n!}.$$

式中满足$\mathbf{W}_d=-\mathbf{W}_d^T$，$\mathbf{W}_d$的参数随机初始化。尽管指数映射为无穷级数，但仅取前有限项即可得到精度足够高的结果，计算开销极低。最终截断$\exp(\mathbf{W}_d)$的列向量，使其维度匹配S_d的特征维度，即可得到投影层$\mathcal{M}_d$。客户端通过式 (9) 反向传播更新$\mathbf{W}_d$参数。借助正交投影，特征仅经过线性变换，既避免知识冲突，又保留特征原始形态，最大化可迁移知识量。

经过正交投影后，$\mathcal{M}_d(wx)$与e^d维度保持一致。接下来，我们以 KL 散度为损失，同步更新全局模型参数 w 与所有投影层$\{\mathcal{M}_2,\mathrm{dots},\mathcal{M}_m\}$，完成特征表征对齐，优化目标为：

$$\min_{w,\{\mathcal{M}_2,\ldots,\mathcal{M}_m\}} \frac{1}{m-1}\sum_{i=2}^{m} KL(\mathcal{M}_i(wx), e^i). \tag{9}$$

知识蒸馏完成后，服务器将更新后的全局模型 w 下发至客户端，用于下一轮通信迭代。

模块化特性。FedFD 具备模块化的核心优势：现有各类联邦学习算法均可无缝接入 FedFD，将其作为即插即用的增强模块，具体优势如下：

1. 优化兼容性：本文框架可兼容除 HeteroFL [6] 以外的各类全局聚合方法更新全局模型，同时保留原有算法的收敛优势。
2. 隐私安全：FedFD 与标准联邦学习算法的通信量完全一致，不会出现上传生成模型、额外原型信息等带来的隐私泄露风险。
3. 灵活拓展性：尽管本文实验引入额外蒸馏数据集，但本框架可与现有无数据蒸馏技术结合，能够根据资源约束、计算开销灵活选择蒸馏数据集方案。

4 实验

本节采用三组数据集、多种对比基线对所提方法开展评估，探究数据异构程度与训练效率之间的关联；同时通过消融实验分析 FedFD 各核心模块的作用，最后开展参数敏感性分析，验证本方法的有效性。

4.1 实验设置

数据集：本文在三组数据集上采用非独立同分布划分方案开展实验，分别为 CIFAR-10、CIFAR-100 [19]、Tiny-ImageNet [20]。参照文献 [58,49]，采用狄利克雷分布$Dir(\alpha)$对标签做划分，模拟数据异构场景。全部训练样本分配至各客户端，所有测试样本统一用于性能评估。

对比基线：为保证对比公平，本文遵循文献 [6] 的实验设定搭建异构模型联邦蒸馏任务，标记后缀“-hetero”。对比方法分为三类：

(1) 经典联邦学习算法：HeteroFL [6]、MOON-hetero [22];

(2) 面向同构模型的联邦蒸馏算法：FedFusion-hetero [33]、FedGen-hetero [58]、DaFKD-hetero [49];

(3) 面向异构模型的联邦蒸馏算法：FedMD [21]、MSFKD [48]、FedGD [55]。

实验配置：若无特殊说明，本地训练轮次 **E=10**，总通信轮次 **T=200**，客户端总数 **K=20**，每轮活跃客户端占比 **r=0.4**。本地训练批次大小 64，权重衰减系数 **1e-4**；蒸馏学习率 0.01，本地模型训练学习率 0.001。服务器端全局模型骨干网络选用 ResNet-18 [11]。参照文献 [6]，构建 10 种计算复杂度梯度的模型架构$\{a,b,c,\cdots,j\}$，隐藏通道衰减比例 10%。例如模型 a 保留全部参数，模型 b、c 分别保留 90%、80% 有效参数。本文实验选用 a、d、g 三种架构，4.2 节补充更多架构组合实验。所有补充实验均基于全局模型精度做统计分析，与文献 [6] 保持一致。

4.2 整体性能对比

表 1 各方法在不同数据异构度下全局 / 本地测试精度

分类	算法	指标	CIFAR-10			CIFAR-100			Tiny-ImageNet		
			α=10	α=1	α=0.1	α=10	α=1	α=0.1	α=10	α=1	α=0.1
传统 FL	HeteroFL	本地	80.11 ±0.95	75.83 ±1.35	63.53 ±4.66	53.37 ±1.11	49.33 ±1.76	38.07 ±4.52	29.71±2 .85	24.12 ±5.03	18.54 ±3.40
		全局	88.45 ±0.03	87.53 ±0.15	78.02 ±0.65	58.51 ±0.19	57.42 ±0.12	53.98 ±0.43	32.38±0 .51	29.88 ±2.72	23.25 ±2.96
	MOON-hetero	本地	80.53 ±0.77	75.87 ±0.99	63.98 ±3.20	52.85 ±2.03	50.21 ±2.42	38.21 ±3.61	28.36±1 .70	24.47 ±2.42	17.94 ±2.51

分类	算法	指标	CIFAR-10			CIFAR-100			Tiny-ImageNet		
		全局	88.05±0.14	87.92±0.17	79.05±0.89	58.39±0.20	57.55±0.17	55.01±0.34	31.28±1.61	30.68±1.92	24.91±1.78
同构蒸馏	FedFusion-hetero	本地	82.35±0.51	75.27±1.00	62.20±5.37	51.23±1.73	48.21±2.08	37.53±5.15	33.98±2.07	25.62±2.29	20.31±5.25
		全局	86.69±0.30	85.70±0.15	78.47±1.11	59.53±0.11	58.86±0.12	56.12±0.35	35.05±1.87	31.56±1.23	26.09±0.73
	FedGen-hetero	本地	82.29±0.62	76.01±0.97	62.74±3.17	51.99±3.67	47.80±1.12	39.79±6.02	34.04±2.93	25.37±2.56	21.77±6.89
		全局	87.34±0.07	86.81±0.08	79.22±2.03	58.49±0.06	57.63±0.86	56.05±0.52	34.71±1.90	32.00±1.56	26.84±1.52
	DaFKD-hetero	本地	83.83±1.01	77.69±2.06	64.71±2.29	52.76±3.33	48.99±1.73	39.98±5.09	33.85±0.96	26.02±3.19	22.26±4.49
		全局	89.26±0.31	87.84±0.64	80.07±1.23	58.97±0.43	58.52±0.19	57.33±1.00	35.69±1.48	32.57±1.34	26.54±1.73
异构蒸馏	FedMD	本地	70.33±3.98	63.47±4.13	60.67±5.09	42.28±6.11	39.64±5.45	26.90±7.70	23.84±3.76	19.37±3.20	13.89±6.70
		全局	78.91±2.32	75.48±3.31	66.67±2.50	46.37±3.11	49.40±4.65	39.44±9.89	26.37±2.80	22.60±2.43	19.42±3.17
	MSFKD	本地	82.26±0.63	77.31±3.04	62.52±9.36	52.06±2.20	49.94±1.27	39.72±3.70	34.30±3.11	27.93±2.71	22.59±5.84
		全局	87.79±0.18	86.98±0.31	80.00±1.75	58.88±0.38	59.09±0.24	56.29±0.83	36.29±0.60	31.62±0.87	26.70±2.33
	FedGD	本地	82.40±1.01	76.02±1.39	63.71±8.06	51.02±2.07	50.17±1.86	39.17±2.78	35.08±2.55	26.50±1.64	23.47±4.83
		全局	87.52±0.24	87.22±0.13	79.31±0.75	59.26±0.41	58.03±0.26	56.34±0.65	36.86±1.06	30.66±1.59	27.53±2.20

分类	算法	指标	CIFAR-10			CIFAR-100			Tiny-ImageNet		
	FedFD (本文)	本地	84.91 ±0.42	78.03 ±1.49	65.33 ±9.22	54.98 ±1.76	52.24 ±1.90	41.68 ±4.12	36.78±5 .13	30.90 ±5.25	23.41 ±4.99
		全局	90.06 ±0.03	89.64 ±0.23	82.74 ±0.58	61.07 ±0.22	60.86 ±0.10	59.24 ±0.48	40.27±1 .33	34.24 ±1.13	29.09 ±1.69

测试精度：表 1 展示三组数据集、不同数据异构程度下各类方法的测试精度。每组实验重复两次，取最后 10 轮精度计算均值与标准差，同时汇报全局模型精度与所有客户端本地模型平均精度。首先可以观察到，全局模型性能显著优于本地模型。对于经典联邦学习方法，MOON 在异构模型场景下无明显性能优势，说明不同架构间的对比损失带来的提升十分有限。对于面向同构模型的联邦蒸馏方法：对数输出蒸馏虽存在精度波动，但随着训练轮数增加可带来一定性能提升。FedGen 与 DaFKD 均属于无数据蒸馏方法，相比 FedFusion，二者性能提升幅度低于原文报道结果，推测原因是生成器训练不稳定，且本文采用的数据集复杂度高于 MNIST 手写数字数据集。对于异构联邦学习专用方法：FedMD 因缺少参数聚合步骤性能较差；其余两种方法基于对数输出蒸馏范式，取得相对不错的效果。本文所提 FedFD 在全部实验条件下性能最优，全局模型测试精度最高提升 16.09%。

表 2 各算法达到目标精度所需通信轮次（α=1.0，最优加粗）

算法	CIFAR-10		CIFAR-100		Tiny-ImageNet	
	Acc=70%	Acc=80%	Acc=55%	Acc=60%	Acc=25%	Acc=30%
HeteroFL	12±3	25±6	20±3	>200	124±16	>200
MOON-hetero	11±4	26±7	22±9	>200	100±9	188±7
FedFusion-hetero	20±7	52±7	61±11	>200	96±25	153±28

算法	CIFAR-10		CIFAR-100		Tiny-ImageNet	
FedGen-hetero	21±11	38±15	198±20	>200	115±12	176±24
DaFKD-hetero	23±9	41±9	44±13	191±27	85±8	126±21
FedMD	62±20	>200	139±21	>200	>200	>200
MSFKD	19±9	45±17	33±10	171±20	87±22	115±31
FedGD	17±8	34±5	40±12	189±21	106±14	150±23
FedFD (本文)	10±5	20±9	16±6	60±18	67±8	99±19

通信效率：表 2 统计各类方法达到指定精度所需通信轮次，用于对比通信效率，图 4 展示对应学习曲线。尽管知识蒸馏类方法能够加快模型收敛，但前文已详细说明对数输出蒸馏训练过程不稳定。而 FedFD 在特征蒸馏中引入正交投影技术，训练过程稳定且收敛速度最快。

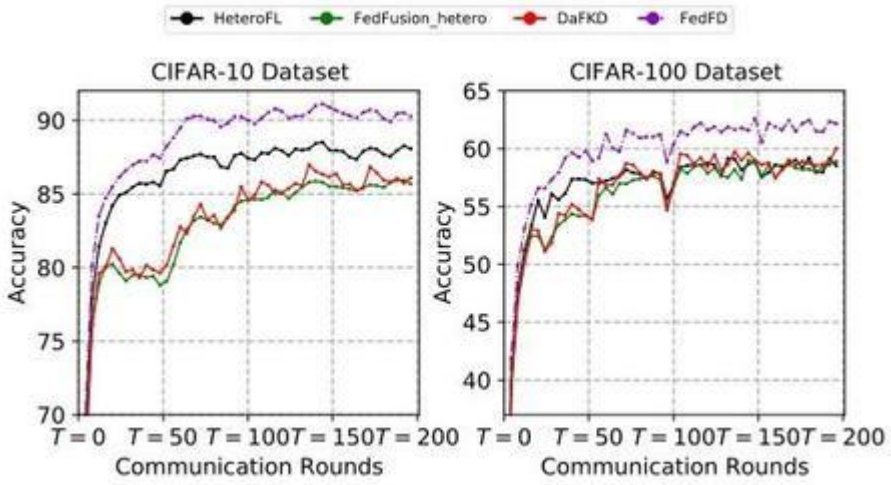


图 4：不同方法在两个数据集上的收敛速度与训练效率对比曲线。

表 3 FedFD 消融实验

方法	CIFAR-10		CIFAR-100	
	α=1.0	α=0.1	α=1.0	α=0.1
FedFD 完整模型	89.64	82.74	60.86	59.24
移除分层特征对齐	89.01	81.56	59.77	58.67

方法	CIFAR-10		CIFAR-100	
移除正交投影	87.96	80.92	59.33	57.29
同时移除两大模块	85.70	78.47	58.86	56.12

消融实验：如表 3 所示，消融实验分别验证两大核心模块的作用。“-w/o feature alignment”代表移除分层特征对齐模块，“-w/o orthogonal projection”代表移除正交投影模块。对比完整 FedFD，移除正交投影后性能下降 0.63%~2.43%；同时移除两个模块时性能出现大幅衰减。其中正交投影对测试精度提升贡献更大；分层特征对齐对精度影响相对较小，其核心价值在于降低服务器存储开销。实验结果证明两个模块对于训练高性能异构联邦学习模型均不可或缺。

数据异构性分析：表 1 反映不同数据异构程度下测试精度变化规律：所有方法均随α增大（数据异构减弱）精度持续提升。同时数据异构对本地模型的负面影响远大于全局模型。特别当$\alpha = 0.1$时，所有基线方法在 CIFAR-100 数据集上本地模型性能大幅下滑，凸显研究异构联邦学习的必要性 —— 本地模型更容易受数据分布偏移影响。而 FedFD 在全部异构程度设置下均稳定优于其他方法，提升幅度最显著。

表 4 多模型组合异构实验（CIFAR-10，α=1.0）

算法	Model Heterogeneity			
	a-d-g	a-f	b-d-f	a-c-d-f-i
HeteroFL	87.53±0.15	88.15±0.18	85.01±0.30	82.53±0.27
FedFusion-hetero	85.70±0.15	86.85±0.10	85.37±0.28	84.10±0.15
FedGD	87.96±0.08	88.47±0.21	85.23±0.40	84.01±0.46
FedFD (本文)	89.64±0.23	89.92±0.19	87.47±0.35	85.92±0.28

参数敏感性分析。在本节中，我们首先探究不同模型带来的模型异构性问题。如表 4 所示，我们选用 4 种不同模型开展实验，并设定：参与模型的数量越多，代表模型异构程度越高。随着异构程度升高，所有算法的效果均出现下滑，其中 FedFusion 的性能下降尤为明显。这一结果印证了逻辑蒸馏（logit 蒸馏）在模型异构场景下存在缺陷。与之相比，FedFD 始终能够保持更优异的性能表现。

接下来我们验证所提方法的可扩展性。如表 5 所示，尽管在大规模实验（强制让部分客户端仅持有极少量样本）的设置下，所有方法的效果都出现了明显衰减，但 FedFD 的表现依旧优于其余对比基线算法，证明了该方法具备出色的鲁棒性与实用有效性。

表 5 极端低数据量可扩展性（α=0.01）

数据集	HeteroFL	FedFusion-hetero	MSFKD	FedFD (本文)
CIFAR-10	63.29±5.19	64.14±8.16	65.30±6.77	67.03±9.34
CIFAR-100	44.59±1.32	45.31±1.09	44.90±2.73	48.05±2.41
Tiny-ImageNet	21.86±4.33	22.97±2.89	23.26±2.54	25.12±1.53

表 6 CNN/ResNet 跨架构适配实验

算法	CIFAR-10		CIFAR-100		Tiny-ImageNet	
	α=1.0	α=0.1	α=1.0	α=0.1	α=10	α=1
FedMD	67.59±3.61	53.10±9.23	30.52±3.98	24.47±1.70	21.29±1.67	19.95±2.80
FedFD	71.28±1.25	59.51±7.13	34.93±0.26	28.98±0.74	30.79±1.28	27.96±0.47

模型架构。尽管上述实验已经验证了 FedFD 在 HeteroFL 框架下的有效性，但从本质上来说，FedFD 是一种改进型特征蒸馏方法，不依赖特定的模型架构与参数聚合策略。本次选用 HeteroFL 作为实验框架，是因为该框架认可度高，

便于和其他基线方法开展全面对比。为排除 HeteroFL 框架本身可能带来的干扰，我们在表 6 中基于两种不同模型架构完成了对照实验。实验中采用 FedMD 算法执行知识蒸馏，直接融合各客户端的知识。实验结果证明，FedFD 能够适配多种不同的模型架构，具备良好的架构通用性。

5 结论

本文提出简洁高效的 FedFD 框架，用于解决联邦学习中异构模型下的特征蒸馏问题。FedFD 可作为任意支持全局模型聚合的联邦学习算法轻量化个性化拓展模块，同时保障隐私安全与通信效率。大量实验证明 FedFD 能够稳定提升模型测试精度。

致谢与基金支持

本研究受国家重点研发计划（2024YFC3307900）、国家自然科学基金（62376103、62302184、62436003、62206102）、湖北省重大科技专项（2024BAA008）、湖北省科技人才专项（2024DJC078）、CCF 蚂蚁科研基金、中央高校基础科研基金（YCJJ20252319）资助。全部计算工作依托华中科技大学高性能计算平台完成。

参考文献

[1] Lucas Beyer, Xiaohua Zhai, Amélie Royer, Larisa Markeeva, Rohan Anil, and Alexander Kolesnikov. Knowledge distillation: A good teacher is patient and consistent. In Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, pages 10925–10934, 2022.

[2] Ilai Bistritz, Ariana Mann, and Nicholas Bambos. Distributed distillation for on-device learning. In Proceedings of Advances in Neural

Information Processing Systems 33: Annual Conference on Neural Information Processing Systems, NeurIPS, 2020.

[3] Arthur Cayley. The collected mathematical papers, volume 7. University, 1894.

[4] Hong-You Chen and Wei-Lun Chao. Fedbe: Making bayesian model ensemble applicable to federated learning. In 9th International Conference on Learning Representations, ICLR 2021, Virtual Event, Austria, May 3-7, 2021.

[5] Pengguang Chen, Shu Liu, Hengshuang Zhao, and Jiaya Jia. Distilling knowledge via knowledge review. In Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, pages 5008–5017, 2021.

[6] Enmao Diao, Jie Ding, and Vahid Tarokh. Heterofl: Computation and communication efficient federated learning for heterogeneous clients. arXiv preprint arXiv:2010.01264, 2020.

[7] Jiahua Dong, Hongliu Li, Yang Cong, Gan Sun, Yulun Zhang, and Luc Van Gool. No one left behind: Real-world federated class-incremental learning. IEEE Transactions on Pattern Analysis and Machine Intelligence, 46(4):2054–2070, 2024.

[8] Jia Guo, Minghao Chen, Yao Hu, Chen Zhu, Xiaofei He, and Deng Cai. Reducing the teacher-student gap via spherical knowledge disitllation. arXiv preprint arXiv:2010.07485, 2020.

[9] Qiushan Guo, Xinjiang Wang, Yichao Wu, Zhipeng Yu, Ding Liang, Xiaolin Hu, and Ping Luo. Online knowledge distillation via collaborative learning. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, CVPR, pages 11020–11029, 2020.

[10] Zhiwei Hao, Jianyuan Guo, Kai Han, Yehui Tang, Han Hu, Yunhe Wang, and Chang Xu. One-forall: Bridge the gap between heterogeneous architectures in knowledge distillation. Advances in Neural Information Processing Systems, 36:79570–79582, 2023.

[11] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In Proceedings of the IEEE conference on computer vision and pattern recognition, pages 770–778, 2016.

[12] Ping He, Xiaohua Xu, Jie Ding, and Baichuan Fan. Low-rank nonnegative matrix factorization on stiefel manifold. Information Sciences, 514:131–148, 2020.

[13] Byeongho Heo, Jeesoo Kim, Sangdoo Yun, Hyojin Park, Nojun Kwak, and Jin Young Choi. A comprehensive overhaul of feature distillation. In Proceedings of the IEEE/CVF international conference on computer vision, pages 1921–1930, 2019.

[14] Geoffrey Hinton, Oriol Vinyals, and Jeff Dean. Distilling the knowledge in a neural network. arXiv preprint arXiv:1503.02531, 2015.

[15] Eunjeong Jeong, Seungeun Oh, Hyesung Kim, Jihong Park, Mehdi Bennis, and Seong-Lyun Kim. Communication-efficient on-device machine

learning: Federated distillation and augmentation under non-iid private data. CoRR, abs/1811.11479, 2018.

[16] Ying Jin, Jiaqi Wang, and Dahua Lin. Multi-level logit distillation. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pages 24276–24285, 2023.

[17] Honggu Kang, Seohyeon Cha, Jinwoo Shin, Jongmyeong Lee, and Joonhyuk Kang. Nefl: Nested federated learning for heterogeneous clients. arXiv preprint arXiv:2308.07761, 2023.

[18] Youmin Kim, Jinbae Park, YounHo Jang, Muhammad Ali, Tae-Hyun Oh, and Sung-Ho Bae. Distilling global and local logits with densely connected relations. In Proceedings of the IEEE/CVF International Conference on Computer Vision, pages 6290–6300, 2021.

[19] Alex Krizhevsky, Geoffrey Hinton, et al. Learning multiple layers of features from tiny images. 2009.

[20] Ya Le and Xuan Yang. Tiny imagenet visual recognition challenge. CS 231N, 7(7):3, 2015.

[21] Daliang Li and Junpu Wang. Fedmd: Heterogenous federated learning via model distillation. arXiv preprint arXiv:1910.03581, 2019.

[22] Qinbin Li, Bingsheng He, and Dawn Song. Model-contrastive federated learning. In Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, pages 10713–10722, 2021.

[23] Tian Li, Anit Kumar Sahu, Ameet Talwalkar, and Virginia Smith. Federated

learning: Challenges, methods, and future directions. IEEE signal processing magazine, 37(3):50–60, 2020.

[24] Xiaojie Li, Jianlong Wu, Hongyu Fang, Yue Liao, Fei Wang, and Chen Qian. Local correlation consistency for knowledge distillation. In European Conference on Computer Vision, pages 18–33. Springer, 2020.

[25] Yichen Li, Qunwei Li, Haozhao Wang, Ruixuan Li, Wenliang Zhong, and Guannan Zhang. Towards efficient replay in federated incremental learning. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), pages 12820–12829, June 2024.

[26] Yichen Li, Qiyu Qin, Gaoyang Zhu, Wenchao Xu, Haozhao Wang, Yuhua Li, Rui Zhang, and Ruixuan Li. A systematic survey on federated sequential recommendation. arXiv preprint arXiv:2504.05313, 2025.

[27] Yichen Li, Yijing Shan, Yi Liu, Haozhao Wang, Wei Wang, Yi Wang, and Ruixuan Li. Personalized federated recommendation for cold-start users via adaptive knowledge fusion. In Proceedings of the ACM on Web Conference 2025, WWW '25, page 2700–2709, New York, NY, USA, 2025.

[28] Yichen Li, Haozhao Wang, Yining Qi, Wei Liu, and Ruixuan Li. Re-fed+: A better replay strategy for federated incremental learning. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2025.

[29] Yichen Li, Haozhao Wang, Wenchao Xu, Tianzhe Xiao, Hong Liu, Minzhu Tu, Yuying Wang, Xin Yang, Rui Zhang, Shui Yu, Song Guo, and Ruixuan

Li. Unleashing the power of continual learning on non-centralized devices: A survey, 2024.

[30] Yichen Li, Yuying Wang, Haozhao Wang, Yining Qi, Tianzhe Xiao, and Ruixuan Li. Fedssi: Rehearsalfree continual federated learning with synergistic synaptic intelligence. In Forty-second International Conference on Machine Learning.

[31] Yichen Li, Wenchao Xu, Haozhao Wang, Ruixuan Li, Yining Qi, and Jingcai Guo. Personalized federated domain-incremental learning based on adaptive knowledge matching, 2024.

[32] Yijing Li, Xiaofeng Tao, Xuefei Zhang, Junjie Liu, and Jin Xu. Privacy-preserved federated learning for autonomous driving. IEEE Transactions on Intelligent Transportation Systems, 23(7):8423–8434, 2021.

[33] Tao Lin, Lingjing Kong, Sebastian U Stich, and Martin Jaggi. Ensemble distillation for robust model fusion in federated learning. Advances in Neural Information Processing Systems, 33:2351–2363, 2020.

[34] Brendan McMahan, Eider Moore, Daniel Ramage, Seth Hampson, and Blaise Aguera y Arcas. Communication-efficient learning of deep networks from decentralized data. In Artificial intelligence and statistics, pages 1273–1282. PMLR, 2017.

[35] Roy Miles, Ismail Elezi, and Jiankang Deng. Vkd: Improving knowledge distillation using orthogonal projections. In Proceedings of the IEEE/CVF

Conference on Computer Vision and Pattern Recognition, pages 15720–15730, 2024.

[36] Roy Miles, Adrian Lopez Rodriguez, and Krystian Mikolajczyk. Information theoretic representation distillation. arXiv preprint arXiv:2112.00459, 2021.

[37] Dinh C Nguyen, Quoc-Viet Pham, Pubudu N Pathirana, Ming Ding, Aruna Seneviratne, Zihuai Lin, Octavia Dobre, and Won-Joo Hwang. Federated learning for smart healthcare: A survey. ACM Computing Surveys (CSUR), 55(3):1–37, 2022.

[38] Yulei Niu, Long Chen, Chang Zhou, and Hanwang Zhang. Respecting transfer gap in knowledge distillation. Advances in Neural Information Processing Systems, 35:21933–21947, 2022.

[39] Kilian Pfeiffer, Martin Rapp, Ramin Khalili, and Jörg Henkel. Federated learning for computationally constrained heterogeneous devices: A survey. ACM Computing Surveys, 55(14s):1–27, 2023.

[40] Bjarne Pfitzner, Nico Steckhan, and Bert Arnrich. Federated learning in a medical context: a systematic literature review. ACM Transactions on Internet Technology (TOIT), 21(2):1–31, 2021.

[41] [41] Adriana Romero, Nicolas Ballas, Samira Ebrahimi Kahou, Antoine Chassang, Carlo Gatta, and Yoshua Bengio. Fitnets: Hints for thin deep nets, 2015.

[42] V Sanh. Distilbert, a distilled version of bert: smaller, faster, cheaper and

lighter. arXiv preprint arXiv:1910.01108, 2019.

[43] Jiawei Shao, Fangzhao Wu, and Jun Zhang. Selective knowledge sharing for privacy-preserving federated distillation without a good teacher. Nature Communications, 15(1):349, 2024.

[44] Yonglong Tian, Dilip Krishnan, and Phillip Isola. Contrastive representation distillation. arXiv preprint arXiv:1910.10699, 2019.

[45] Laurens Van der Maaten and Geoffrey Hinton. Visualizing data using t-sne. Journal of machine learning research, 9(11), 2008.

[46] Chunnan Wang, Xiang Chen, Junzhe Wang, and Hongzhi Wang. Atpfl: Automatic trajectory prediction model design under federated learning framework. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pages 6563–6572, 2022.

[47] Chunnan Wang, Xiang Chen, Junzhe Wang, and Hongzhi Wang. ATPFL: automatic trajectory prediction model design under federated learning framework. In IEEE/CVF Conference on Computer Vision and Pattern Recognition, CVPR, New Orleans, LA, USA,June 18-24,June 18-24, pages 6553–6562, 2022.

[48] Dong Wang, Naifu Zhang, Meixia Tao, and Xu Chen. Knowledge selection and local updating optimization for federated knowledge distillation with heterogeneous models. IEEE Journal of Selected Topics in Signal Processing, 17(1):82–97, 2022.

[49] Haozhao Wang, Yichen Li, Wenchao Xu, Ruixuan Li, Yufeng Zhan, and

Zhigang Zeng. Dafkd: Domainaware federated knowledge distillation. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pages 20412–20421, 2023.

[50] Haozhao Wang, Haoran Xu, Yichen Li, Yuan Xu, Ruixuan Li, and Tianwei Zhang. Fedcda: Federated learning with cross-rounds divergence-aware aggregation. In The Twelfth International Conference on Learning Representations, 2023.

[51] Kaibin Wang, Qiang He, Feifei Chen, Chunyang Chen, Faliang Huang, Hai Jin, and Yun Yang. Flexifed: Personalized federated learning for edge clients with heterogeneous model architectures. In Proceedings of the ACM Web Conference 2023, pages 2979–2990, 2023.

[52] Chuhan Wu, Fangzhao Wu, Lingjuan Lyu, Yongfeng Huang, and Xing Xie. Communication-efficient federated learning via knowledge distillation. Nature communications, 13(1):2032, 2022.

[53] Guile Wu and Shaogang Gong. Peer collaborative learning for online knowledge distillation. In Proceedings of the AAAI Conference on Artificial Intelligence, AAAI, 2021.

[54] Junho Yim, Donggyu Joo, Jihoon Bae, and Junmo Kim. A gift from knowledge distillation: Fast optimization, network minimization and transfer learning. In Proceedings of the IEEE conference on computer vision and pattern recognition, pages 4133–4141, 2017.

[55] Jie Zhang, Chen Chen, Weiming Zhuang, and Lingjuan Lyu. Target:

Federated class-continual learning via exemplar-free distillation. In Proceedings of the IEEE/CVF International Conference on Computer Vision, pages 4782–4793, 2023.

[56] Lin Zhang, Li Shen, Liang Ding, Dacheng Tao, and Ling-Yu Duan. Fine-tuning global model via data-free knowledge distillation for non-iid federated learning. In IEEE/CVF Conference on Computer Vision and Pattern Recognition, CVPR 2022, New Orleans, LA, USA, June 18-24, 2022, pages 10164–10173.

[57] Borui Zhao, Quan Cui, Renjie Song, Yiyu Qiu, and Jiajun Liang. Decoupled knowledge distillation. In Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, pages 11953–11962, 2022.

[58] Zhuangdi Zhu, Junyuan Hong, and Jiayu Zhou. Data-free knowledge distillation for heterogeneous federated learning. In International Conference on Machine Learning, pages 12878–12889. PMLR, 2021.

NeurIPS 论文自查清单

1 研究主张

问题：摘要与引言提出的核心主张是否准确反映本文贡献与研究范围？

回答：[是]

说明：摘要与引言完整总结了论文全部贡献。

说明：回答“不适用”代表摘要、引言无核心研究主张；审稿人不接受“否 / 不适用”答复。

- 所有结论、主张必须匹配理论与实验结果，明确泛化边界；
- 可写入远期研究愿景，但需注明本文未实现该目标。

2 研究局限性

问题：文章是否讨论本方法存在局限？

回答：[是]

说明：文中已阐述本工作存在局限。

说明：回答“不适用”代表无局限；回答“否”代表存在局限但未说明。

- 建议单独设立局限性小节；
- 完整列出全部关键假设，分析假设失效带来的性能衰减；
- 说明实验数据集、迭代轮次等约束条件；
- 分析算力、隐私、公平性相关短板；
- 如实说明局限不会被审稿扣分，隐瞒反而降低评价。

3 理论假设与证明

问题：每项理论结论是否完整给出全部前提假设与严谨证明？

回答：[不适用]

说明：本文无全新定理推导。

说明：回答“不适用”代表不存在理论推导内容；

- 定理、公式、证明统一编号交叉引用；
- 证明可置于正文或补充材料，补充材料需提供简要推导思路。

4 实验可复现性

问题：是否完整披露全部实验复现所需信息？

回答：[是]

说明：可提供完整实验细节与代码复现全部结果。

说明：回答“不适用”代表无实验；“否”会严重影响审稿评价。

- 新架构、新算法、大模型需分别提供复现步骤、权重或开源代码；
- NeurIPS 不强制开源，但必须提供可行复现路径。

5 数据与代码开源

问题：是否开源数据、代码并提供完整运行文档？

回答：[是]

说明：审稿需求下可提供完整源代码。

说明：回答“不适用”代表实验无需代码；

- 需完整提供环境配置、运行命令、数据预处理脚本；
- 投稿阶段提供匿名脱敏代码包。

6 实验细节

问题：完整写明训练、测试全部超参、数据划分、优化器信息？

回答：[是]

说明：正文已列出全部实验配置。

说明：完整超参可附代码或附录。

7 实验统计显著性

问题：图表、表格是否标注误差棒、标准差、置信区间？

回答：[是]

说明：全部实验附带误差统计指标。

- 明确误差来源、计算方式、误差类型（标准差 / 标准误）；
- 非对称分布避免不合理对称误差区间。

8 实验算力资源

问题：是否说明复现实验所需硬件、内存、运行时长？

回答：[是]

说明：文中标注实验算力需求。

- 区分单轮算力与整体项目总算力，说明预实验额外开销。

9 伦理规范

问题：全文完全遵循 NeurIPS 伦理准则？

回答：[是]

说明：已通读并遵守会议伦理规范。

10 广泛社会影响

问题：是否同时讨论本工作正负社会影响？

回答：[不适用]

说明：本研究无直接社会落地影响。

- 若存在伪造、监控、歧视等负面应用必须说明缓解方案。

11 安全防护机制

问题：高风险模型 / 数据集是否配套管控方案？

回答：[不适用]

说明：本文无高风险可滥用内容。

12 现有工具版权许可

问题：引用代码、数据集、模型完整标注来源与开源协议？

回答：[是]

说明：全部第三方资源引用原始论文并标注协议。

13 新增数据 / 模型资产

问题：自研数据集、模型附带完整文档同步发布？

回答：[不适用]

说明：本文未发布全新数据集、模型。

14 众包与人受试者实验

问题：涉及人体实验是否附指引、报酬、截图？

回答：[不适用]

说明：无众包、人体受试者实验。

15 伦理审查 IRB 审批

问题：人体实验是否提供伦理审批与风险告知说明？

回答：[不适用]

说明：无人体实验。

16 大语言模型使用声明

问题：大模型是否作为核心创新组件？

回答：[不适用]

说明：核心算法开发未使用大语言模型。